



پردیس علوم
دانشکده ریاضی، آمار و علوم کامپیوتر

شناسایی اختلالات روانی با اعمال الگوریتم‌های یادگیری ماشین بر روی سیگنال EEG

نگارنده

نیلوفر بابا احمدی

استاد راهنما: باقر باباعلی

پایان‌نامه برای دریافت درجه کارشناسی
در رشته علوم کامپیوتر

تیر ۱۴۰۲

چکیده

در این گزارش، ما به طبقه‌بندی اختلالات عصبی بر اساس داده‌های EEG می‌پردازیم و به منظور بررسی عملکرد مدل‌ها، مدل‌های رگرسیون لجستیک، ماشین بردار پشتیبان و جنگل تصادفی را بر روی این داده‌ها تست کردیم. نتایج حاصل از آزمایشات نشان می‌دهد که مدل ماشین بردار پشتیبان برای طبقه‌بندی اختلالات اصلی، عملکرد بهتری داشته است و مدل رگرسیون لجستیک نیز برای طبقه‌بندی اختلالات جزئی، نتیجه‌های بهتری ارائه کرده است. داده‌های مورد استفاده شامل IQ، سن، جنسیت، تشخیص‌های پزشکی و ویژگی‌های PSD امواج EEG و همچنین ویژگی‌های FC بود. مجموعاً، ما دارای ۹۴۵ نمونه داده بودیم که ۸۵۰ نمونه از آن‌ها مربوط به بیماران مبتلا به اختلالات عصبی بودند و ۹۵ نمونه دیگر سالم بودند. نتایج حاصل از این پروژه نشان می‌دهد که استفاده از ویژگی‌های EEG می‌تواند در تشخیص و طبقه‌بندی اختلالات عصبی مؤثر باشد و استفاده از مدل‌های مختلف یادگیری ماشین با توجه به نوع اختلال می‌تواند به دقت و عملکرد بهتر در این زمینه منجر شود.

سپاسگزاری

از دکتر باباعلی که راهنمایی این پروژه را انجام دادند و با کمک های بسیارشان در طول پروژه به آن مسیر بخشیدند، بسیار تشکر می‌کنم.

پیشگفتار

تشخیص دقیق و به موقع اختلالات روانی از جمله مسائل حیاتی در حوزه بهداشت روانی محسوب می‌شود. این اختلالات می‌توانند تأثیرات عمیقی بر روی زندگی افراد داشته باشند و باعث کاهش کیفیت زندگی و عملکرد اجتماعی آن‌ها گردند. با پیشرفت تکنولوژی‌های پیشرفته در حوزه علوم داده و هوش مصنوعی، امکان استفاده از داده‌های عصبی و روش‌های تحلیل داده به منظور تشخیص اختلالات روانی به شکل دقیق‌تر و مؤثرتر فراهم آمده است. هوش مصنوعی، به ویژه یادگیری ماشین، قابلیت تشخیص الگوها و روندهای پنهان در داده‌ها را دارد که این امر به محققان و پزشکان اجازه می‌دهد تا با اطمینان بیشتری به تشخیص صحیح اختلالات روانی بپردازند. بنابراین، بهره‌گیری از داده‌ها و هوش مصنوعی به عنوان ابزاری قدرتمند و مؤثر در تشخیص و درمان اختلالات روانی، توجه بسیاری از پژوهشگران و ارائه‌دهندگان خدمات بهداشتی را به خود جلب کرده است.

در روش‌های استاندارد بالینی، اختلالات روانی بر اساس طبقه‌بندی و پدیدارشناسی تشخیص داده می‌شوند. اما این رویکرد به دلیل اعتماد به مشاهدات پزشک و علائم گزارش‌شده توسط بیمار یا افراد نزدیک به وی، ممکن است اهداف آزمون‌پذیری را محدود کند. برخی مطالعات نشان داده‌اند که تمرکز بر علائم، تداوم درمان را محدود می‌کند؛ بنابراین استفاده از رویکردهای مبتنی بر داده‌ها می‌تواند به عنوان یک کمک در تشخیص مورد استفاده قرار گیرد.

پیشرفت‌های تکنولوژی در علوم داده و محاسبات، در حوزه بهداشت روانی تغییراتی را به دنبال داشته‌اند. امکان اندازه‌گیری شواهد عصبی و نشانگرها، به شدت گسترش یافته است. همچنین استفاده از یادگیری ماشین و هوش مصنوعی نیز افزایش یافته است. با استفاده از برآوردهای نمونه بیرونی، یادگیری ماشین می‌تواند عملکرد پیش‌بینی‌ها را در داده‌های ناشناخته ارزیابی کند. این روش اطلاعات شخصی‌سازی شده ارائه داده و نتایجی با قابلیت انتقال بالقوه در بخش بالینی به دست می‌دهد.

ادبیات نشان می‌دهد که یادگیری ماشین می‌تواند با دقت بیش از ۷۵٪ [۷]، اختلالات روانی را تشخیص دهد. در یک مطالعه اخیر [۸]، با استفاده از یادگیری طیف الکتروآنسفالوگرافی و روش تحلیل تشخیص خطی، می‌توان بیماران اسکیزوفرنی را با دقت ۶۶.۸۰٪ از افراد سالم تمایز داد؛ اما معمولاً تمایز بین بیماران با اختلال‌های تکی (مانند اسکیزوفرنی، افسردگی، اعتیاد و اختلال استرس پس از ضربه و خواب‌آلودگی) و افراد سالم مورد توجه قرار می‌گیرد. برای توضیح نتایج پارامترهای مختلف EEG از روش رگرسیون لجستیک جریمه‌دار، شبکه الاستیک، نیز به کار رفته

است. هدف اصلی این تحقیق، ایجاد طبقه‌بندی‌های نوآورانه برای تشخیص بیماران مبتلا به اختلالات اصلی روانی از افراد سالم است. به این منظور از روش‌های یادگیری ماشینی از جمله ماشین بردار پشتیبانی و جنگل تصادفی استفاده کرده‌ایم.

فهرست مطالب

۱	مفاهیم مقدماتی	۱
۱	۱.۱ مقدمه‌ای بر محاسبات روانی عصبی	۱.۱
۲	۱.۱.۱ تحلیل داده‌های مغزی	۱.۱.۱
۳	۲.۱.۱ روش‌های جمع‌آوری داده‌های مغزی	۲.۱.۱
۴	۳.۱.۱ طبقه‌بندی اختلالات روانی	۳.۱.۱
۵	۴.۱.۱ روش‌های تشخیص بیماری‌های روانی	۴.۱.۱
۷	۲.۱ مقدمه‌ای بر یادگیری ماشین	۲.۱
۷	۱.۲.۱ تفاوت یادگیری ماشین با یادگیری عمیق و شبکه‌های عصبی	۱.۲.۱
۸	۲.۲.۱ روند کار یادگیری ماشین	۲.۲.۱
۸	۳.۲.۱ روش‌های یادگیری ماشین	۳.۲.۱
۱۰	۴.۲.۱ الگوریتم‌های رایج یادگیری ماشین	۴.۲.۱
۱۱	۳.۱ مقدمه‌ای بر شبکه‌های عصبی	۳.۱
۱۱	۱.۳.۱ شبکه‌های عصبی چگونه کار می‌کنند؟	۱.۳.۱
۱۳	۲.۳.۱ انواع شبکه‌های عصبی	۲.۳.۱
۱۵	۴.۱ مقدمه‌ای بر پردازش سیگنال	۴.۱
۱۵	۱.۴.۱ مفاهیم اصلی پردازش سیگنال	۱.۴.۱
۱۶	۲.۴.۱ روش‌ها و الگوریتم‌های پردازش سیگنال	۲.۴.۱
۱۸	۲ مدل‌ها	۲
۱۹	۱.۲ مدل رگرسیون لجستیک	۱.۲
۲۰	۲.۲ مدل ماشین بردار پشتیبان:	۲.۲
۲۱	۳.۲ مدل جنگل تصادفی	۳.۲
۲۴	۳ نتایج	۳
۲۴	۱.۳ داده‌ها	۱.۳
۲۴	۱.۱.۳ جمع‌آوری داده‌ها	۱.۱.۳
۲۵	۲.۱.۳ تنظیمات و پارامترهای EEG	۲.۱.۳

۲۷	۳.۱.۳ تحلیل داده ها
۳۶	۴.۱.۳ تصویرسازی PSD
۳۹	۲.۳ نتایج مدل ها
۴۳		۴ جمع بندی

فصل ۱

مفاهیم مقدماتی

۱.۱ مقدمه‌ای بر محاسبات روانی عصبی

محاسبات روانی عصبی، همچنین به عنوان علم نوروساینس^۱ شناخته می‌شود، زمینه‌ای پیچیده و هیجان‌انگیز است که به بررسی و تحلیل سیستم عصبی انسان و دیگر موجودات می‌پردازد. این علم بر اساس اصول و مبانی زیست‌شناسی، فیزیولوژی و شناختی، ساختار و عملکرد مغز و سایر اجزای سیستم عصبی را مورد مطالعه قرار می‌دهد.

تا حدود چند دهه پیش، علمای روانشناسی و نوروساینست‌ها برای درک رفتارها و فرآیندهای ذهنی، از مشاهدات رفتاری و روانشناختی بهره می‌بردند. اما با پیشرفت تکنولوژی و ابزارهای علمی، مطالعه سیستم عصبی به صورت مستقیم و با روش‌های علمی و دقیق‌تر امکان‌پذیر شد. این تحول در ابزارها و تکنیک‌ها، به ویژه استفاده از تصویربرداری مغز (مانند MRI و EEG)، امکان مشاهده فعالیت‌های نورونی و تعامل بین اجزای مختلف مغز را به ما می‌دهد.

محاسبات روانی عصبی به دنبال این است که چگونگی ایجاد و پردازش اطلاعات در سیستم عصبی را به طور دقیق‌تر بفهمد. این زمینه با استفاده از تکنیک‌های مدل‌سازی و تجزیه و تحلیل داده‌ها، عملکرد مغز و ارتباط آن با عملکرد شناختی و رفتاری را مورد بررسی قرار می‌دهد. از جمله موضوعات مطرح در محاسبات روانی عصبی می‌توان به موارد زیر اشاره کرد:

۱. مدل‌سازی شبکه‌های عصبی: در این بخش، تلاش می‌شود مدل‌های ریاضی برای شبکه‌های عصبی ساخته شوند و نقش هر نورون و ارتباطات آن با دیگر نورون‌ها مورد بررسی قرار بگیرد. با استفاده از این مدل‌ها، سعی می‌شود به پیچیدگی‌ها و توانایی‌های مغز در فرآیندهای مختلف، مثل تصمیم‌گیری و حل مسائل پیچیده، نیز پی ببریم.

۲. تحلیل داده‌های مغزی: در این حوزه، از داده‌های به دست آمده از تصاویر مغزی و اندازه‌گیری‌های الکتروفیزیولوژیکی (مثل EEG و fMRI) برای درک نحوه فعالیت مغز در طول وظایف شناختی و رفتاری استفاده می‌شود. این تحلیل‌ها به ما اجازه می‌دهند تا به نحوه پردازش اطلاعات حسی و

¹Neuroscience

شناختی توسط مغز هنگام انجام وظایف مختلف، نظیر حل مسائل، تصمیم‌گیری‌ها، و حتی پدیده‌های هنری و خلاقیت، نزدیک‌تر شویم.

۳. یادگیری ماشین و هوش مصنوعی: استفاده از تکنیک‌ها و الگوریتم‌های یادگیری ماشینی در تحلیل داده‌های مغزی و پیش‌بینی ویژگی‌ها و رفتارها بر اساس فعالیت مغزی موضوع مطالعات این بخش از محاسبات روانی عصبی است. با بهره‌گیری از این روش‌ها می‌توان به طبقه‌بندی و تشخیص بیماری‌های روانی نیز پرداخت و نقش معیارهای مغزی در این زمینه را بررسی.

۴. شناخت انسانی: بررسی نحوه پردازش اطلاعات حسی و محاسبات شناختی که مرتبط با عملکرد مغز هنگام انجام وظایف شناختی است، می‌تواند از موضوعات این بخش باشد. با کمک محاسبات روانی عصبی می‌توانیم به نحوه ایجاد حافظه، یادگیری، تصمیم‌گیری و حتی تأثیر عوامل مختلف نظیر تغذیه و تمرین بر عملکرد مغز پی‌ببریم.

۵. محاسبات کوانتومی و مغز: بررسی تأثیر محتمل مکانیک کوانتومی در پردازش اطلاعات توسط سیستم عصبی می‌تواند از موضوعات جالب در محاسبات روانی عصبی باشد. استفاده از مفاهیم کوانتومی ممکن است در تبیین برخی از پدیده‌های پیچیده مغزی، مانند ترکیب اطلاعات و هم‌آمیختگی حافظه‌ها، مفید واقع شود.

هدف اصلی این پژوهش، ایجاد طبقه‌بندی‌های نوآورانه برای تشخیص بیماران مبتلا به اختلالات اصلی روانی از افراد سالم است. برای این منظور، داده‌های EEG بیماران را با شش دسته اصلی اختلالات روانی جمع‌آوری کرده‌ایم و تشخیص‌های خاص آنها را مستثنی می‌کنیم. با استفاده از این داده‌ها و با بهره‌گیری از روش‌های یادگیری ماشینی، مانند ماشین بردار پشتیبانی، جنگل تصادفی، رگرسیون لجستیک جریمه‌دار و شبکه الاستیک، مدل‌های طبقه‌بندی با پارامترهای چندمتغیره EEG ساخته شده است. با توجه به نتایج حاصل، تفاوت‌های اصلی بین اختلالات و نحوه تشخیص و تفسیر داده‌های مغزی به دقت مشخص شده است. این نتایج به نقش کلیدی محاسبات روانی عصبی در تشخیص و درمان اختلالات روانی اشاره می‌کند و همچنین در سایر حوزه‌هایی نظیر پزشکی، روان‌شناسی، هوش مصنوعی، روباتیک و علوم اعصاب کاربردهایی عملی دارد.

۱.۱.۱ تحلیل داده‌های مغزی

تحلیل داده‌های مغزی و طبقه‌بندی بیماری‌های عصبی یک حوزه مهم و پرمخاطب در علم محاسبات روانی عصبی است که با استفاده از تکنیک‌های پیشرفته محاسباتی و هوش مصنوعی به بررسی و تشخیص بیماری‌های روانی می‌پردازد. داده‌های مغزی، از جمله الکتروانسفالوگرام^۲ و تصویربرداری مغناطیسی تابشی^۳، نشان‌دهنده فعالیت‌های نورونی مغز در طول زمان هستند که محتوای اطلاعات مرتبط با وضعیت عملکرد مغزی در هنگام انجام وظایف مختلف را در اختیار ما قرار می‌دهند. با پیشرفت تکنولوژی‌ها و ابزارهای تصویربرداری مغز، مطالعه سیستم عصبی به‌طور مستقیم و با

^۲EEG

^۳fMRI

روش‌های دقیق‌تر امکان‌پذیر شده است. این پیشرفت‌ها، امکان مشاهده و بررسی فعالیت‌های نورونی و تعامل بین اجزای مختلف مغز را به ما می‌دهد. همچنین، با بهره‌گیری از تکنیک‌های محاسباتی پیشرفته و یادگیری ماشینی، می‌توان اطلاعات معنادار و پردازش‌های پیچیده‌تر از این داده‌ها استخراج کرد و به تشخیص بیماری‌های عصبی و رفتارهای مغزی کمک کرد.

برای طبقه‌بندی بیماری‌های عصبی، ابتدا داده‌های EEG از بیماران مختلف با اختلالات روانی مختلف جمع‌آوری می‌شوند. این داده‌ها شامل سیگنال‌های الکتریکی مغزی هستند که نمایانگر فعالیت نورون‌ها در طول زمان است. این سیگنال‌ها اغلب حاوی نویز و اشتباهات هستند که نیاز به پیش‌پردازش و استخراج ویژگی‌های معنادار دارند.

در مرحله پیش‌پردازش، از تکنیک‌های مختلفی مانند حذف نویز، فیلترینگ، نرمال‌سازی و کاهش بعد استفاده می‌شود تا داده‌ها به‌طور موثرتر و دقیق‌تر آماده شوند. در ادامه، با استفاده از تکنیک‌های یادگیری ماشینی و مدل‌سازی ریاضی، ویژگی‌های معنادار از داده‌های EEG استخراج می‌شود. این ویژگی‌ها ممکن است شامل پارامترهای طیفی، زمانی یا فضایی باشند که معمولاً مرتبط با وضعیت عملکرد مغزی و بیماری‌های مختلف هستند.

در مرحله بعدی، با استفاده از ویژگی‌های استخراج‌شده از داده‌های EEG به طبقه‌بندی بیماری‌های عصبی می‌پردازیم.

نتایج حاصل از تحلیل داده‌های مغزی و طبقه‌بندی بیماری‌های عصبی، نقش بسیار مهمی در تشخیص و درمان اختلالات روانی و عصبی ایفا می‌کند. این اطلاعات به پزشکان و متخصصان کمک می‌کند تا تشخیص دقیق‌تری برای بیماران ارائه دهند و روند درمان را بهبود بخشند. همچنین، این تحقیقات به پیشرفت علم محاسبات روانی عصبی و توسعه روش‌های پیشرفته تشخیص بیماری‌های عصبی و به دقت و اعتبار مطالعات آینده در این زمینه کمک می‌کند.

۲.۱.۱ روش‌های جمع‌آوری داده‌های مغزی

جمع‌آوری داده‌های مغزی از بیماران به عنوان یکی از مراحل اساسی در تحلیل و طبقه‌بندی بیماری‌های عصبی، با استفاده از روش‌های محاسبات روانی عصبی، محسوب می‌شود. این داده‌ها، کلیدی‌ترین منبع اطلاعات برای درک عملکرد مغز در وضعیت‌های مختلف و تشخیص بیماری‌های روانی هستند. انتخاب مناسب و صحیح روش‌های جمع‌آوری داده مغزی، مؤثرترین عامل در دقت و کارایی تحلیل‌های بعدی است. در ادامه، به برخی از مهم‌ترین روش‌های جمع‌آوری داده‌های مغزی می‌پردازیم:

۱. الکتروانسفالوگرام: یکی از رایج‌ترین روش‌های جمع‌آوری داده مغزی است که با قرار دادن الکترودها روی فرمانه‌های مغزی، سیگنال‌های الکتریکی تولید شده توسط فعالیت نورونی را ثبت می‌کند. این روش ساده و کاربردی است و به صورت غیرتهاجمی اطلاعاتی از فعالیت مغزی را ارائه می‌دهد.

۲. تصویربرداری مغناطیسی تابشی: این روش بر اساس اثرات مغناطیسی جریان خون در مغز است.

با استفاده از میدان مغناطیسی قوی، تصاویری از ساختارهای مغزی و تغییرات جریان خون در اثر فعالیت نورون‌ها ثبت می‌شود.

۳. تصویربرداری انباشت پوزیترون^۴: این روش از رادیوایون‌های بازیابی شده از جریان‌های خونی که به وسیله‌ی رادیوایون‌های شعاعی پوزیترون به بیمار تزریق می‌شود، استفاده می‌کند.

۴. مگنتوانسفالوگرام^۵: این روش با استفاده از سنسورهای حساس به میدان‌های مغناطیسی تولید شده توسط فعالیت نورونی، سیگنال‌های مغناطیسی مغزی را ثبت می‌کند.

۵. اسپکتروسکوپی اشعه نزدیک نوری^۶: این روش از نورهای قرمز و اشعه نزدیک نوری استفاده می‌کند تا تغییرات حجم خون در ساختارهای مغزی را ثبت کند.

به طور کلی، روش‌های جمع‌آوری داده مغزی با توجه به نیازها و هدف تحلیل‌های بعدی انتخاب می‌شوند. انتخاب روش مناسب می‌تواند روی دقت و کیفیت تحلیل‌های بعدی تاثیر بسزایی بگذارد و در بهبود تشخیص و درمان بیماری‌های عصبی کمک مؤثری باشد.

۳.۱.۱ طبقه‌بندی اختلالات روانی

اختلالات روانی به طور کلی بر اساس مشخصه‌ها، علائم و نمونه‌های رفتاری افراد، توسط متخصصین بهداشت روانی و روان‌شناسان به دسته‌بندی‌های مختلف تقسیم می‌شوند. این دسته‌بندی‌ها به منظور تشخیص و درمان بهتر اختلالات و همچنین برای تحقیقات علمی بیشتر در حوزه بهداشت روانی انجام می‌شود. اختلالات روانی معمولاً در دو دسته اصلی و خاص قرار می‌گیرند [۱۳][۱۴]:

۱. اختلالات اصلی:

- اسکیزوفرنی: که به اختلالی عمده در تفکر، شناخت همراه با اختلالات هیجانی، انرژی و عملکرد اجتماعی اشاره دارد.
- اختلالات خلقی: اختلالات عاطفی هستند که ممکن است شامل افسردگی شدید، تنفر، شادی بیش از حد و یا بی‌احساسی و ناراحتی باشند.
- اختلالات اضطرابی: که شامل انواع اختلالات اضطرابی مانند اضطراب عمومی، اختلال هراس اجتماعی، اختلال هراس و اختلال وسواسی است.
- اختلالات وابستگی: که مرتبط با وابستگی به مواد مخدر و مسببات مختلف نیکوتین، الکل و دیگر مواد مخدر هستند.
- اختلالات مرتبط با تروما و استرس: این اختلالات از واکنش‌های عاطفی و رفتاری پس از تجربه تروما، استرس و رویدادهای ترسناک و ناگوار ناشی می‌شوند.

۲. اختلالات خاص: در این دسته‌بندی خاص، انواع اختلالات و زیرگروه‌هایی که در دسته‌بندی اصلی ذکر شد، مشخص‌تر شده و با جزئیات بیشتری شناخته می‌شوند. به عنوان مثال،

⁴PET

⁵MEG

⁶NIRS

زیرگروه‌هایی همچون اختلال تنظیم، اختلال مصرف الکل، اختلال وسواسی، اختلال اضطرابی اجتماعی و غیره در این دسته‌بندی به کار می‌روند.

این دسته‌بندی‌ها بر اساس معیارهای علمی و استاندارد توسط سازمان‌ها و انجمن‌های علمی معتبر مانند American Psychiatric Association ارائه می‌شوند. این دسته‌بندی‌ها در طول زمان با توجه به پیشرفت‌های علمی و تحقیقاتی ممکن است به‌روزرسانی شده یا تغییر یابند.

۴.۱.۱ روش‌های تشخیص بیماری‌های روانی

تشخیص بیماری‌های روانی یک فرایند پیچیده و چالش‌برانگیز است که نیازمند جمع‌آوری اطلاعات از مختلف منابع و استفاده از روش‌های متنوع است. در زیر، به برخی از مهم‌ترین روش‌های تشخیص بیماری‌های روانی اشاره می‌کنیم:

۱. مصاحبه بالینی: مصاحبه بالینی یکی از مهم‌ترین روش‌های تشخیص بیماری‌های روانی است. در این روش، روانشناس یا پزشک متخصص با بیمار صحبت می‌کند و جزئیاتی از تاریخچه بیماری، علائم و نشانه‌ها، رفتارها، عوامل تحریک‌کننده، و شرایط فعلی بیمار را بررسی می‌کند. مصاحبه‌ها می‌توانند ساختاری یا نیمه ساختاری و به صورت فردی یا گروهی انجام شوند [۱۵].

۲. استفاده از پرسشنامه‌ها و ابزارهای ارزیابی: برخی از پرسشنامه‌ها و ابزارهای ارزیابی می‌توانند در تشخیص بیماری‌های روانی مفید باشند. این ابزارها به عنوان تکمیل‌کننده‌هایی برای مصاحبه‌های بالینی به کار می‌روند. مثال‌هایی از این ابزارها عبارت‌اند از: پرسشنامه اختلالات روانی-رفتاری کودکان و نوجوانان CBCL [۱۶] و مقیاس افسردگی بک [۱۷].

۳. تست‌های روانشناسی: تعدادی از تست‌های روانشناسی نیز ممکن است برای تشخیص بیماری‌های روانی مورد استفاده قرار بگیرند. این تست‌ها عموماً بر مبنای نظریات روانشناسی و روان‌پزشکی ساخته می‌شوند و به عنوان ابزارهای تکمیلی مصاحبه بالینی به کار می‌روند. تست رنگ، تست روانشناسی مینی-منس و تست رابینز^۸ از جمله تست‌های مشهور هستند.

۴. ملاحظات بالینی: ملاحظات بالینی نیز اطلاعات بسیار مهمی را در تشخیص بیماری‌های روانی ارائه می‌دهند. این ملاحظات می‌توانند شامل جزئیاتی از رفتارهای بیمار در زندگی روزمره، تفاوت‌ها نسبت به رفتارهای معمولی و نشانه‌هایی از ناتوانی‌های فردی باشند.

دقت و تخصص کارشناسان حیطه‌ی روانشناسی و روان‌پزشکی در استفاده از این روش‌ها بسیار مهم است. هر یک از روش‌های تشخیص بیماری‌های روانی که مطرح شدند، دارای خطا هستند و خطای آن‌ها می‌تواند تحت تأثیر متغیرهای مختلف قرار بگیرند. به دلیل ماهیت انسان‌محور این روش‌ها، ممکن است در برخی موارد دقت کمتری داشته باشند. اما این خطاها قابل کاهش و مدیریت هستند. به عنوان مثال:

۱. مصاحبه بالینی: مصاحبه بالینی نیازمند مهارت‌های ارتباطی و احتمالاً تجربه بیماری‌های مشابه قبلی است. از طریق مصاحبه، اطلاعات محدودی از بیمار جمع‌آوری می‌شود و ممکن است بیمار

⁷Beck Depression Inventory - BDI

⁸Rorschach

اطلاعات را به دلیل عوامل مختلفی از جمله عواطف و ترس‌ها، تغییر دهد یا ممکن است اطلاعاتی را پنهان کند. همچنین، تجزیه و تحلیل اطلاعات نیز به تجربه و تخصص کارشناس بستگی دارد که ممکن است به عوامل ذاتی انسانی نظیر تعداد بیماران تحت درمان، فرهنگ و باورها، و تفسیرهای شخصی ارتباط داشته باشد.

۲. استفاده از پرسشنامه‌ها و ابزارهای ارزیابی: این ابزارها می‌توانند دقت بالایی داشته باشند، اما هنوز هم به مهارت‌های انسانی برای تفسیر نتایج نیازمند هستند. همچنین، پرسشنامه‌ها ممکن است نتوانند تمام جنبه‌های بیماری‌ها را که ممکن است در مصاحبه بالینی یا مشاهدات بالینی دیده شود، در نظر بگیرند.

استفاده از هوش مصنوعی و داده‌های غیر مشاهده‌ای به عنوان تکمیل‌کننده روش‌های انسان‌محور می‌تواند به دقت و اعتماد به نتایج کمک کند. این رویکرد می‌تواند اطلاعات بیشتری از بیمار جمع‌آوری کند و الگوهای پنهان یا تغییرات غیرقابل تشخیص برای انسان‌ها را شناسایی کند. هوش مصنوعی می‌تواند به عنوان ابزاری برای تحلیل داده‌ها و تشخیص الگوها و ارتباطات پنهان استفاده شود که ممکن است بهبود نتایج در تشخیص بیماری‌های روانی و افزایش دقت در تشخیص‌ها را فراهم کند.

به هر حال، در استفاده از هوش مصنوعی و داده‌های غیر مشاهده‌ای، نیاز به دقت و اعتماد در جمع‌آوری و تجزیه و تحلیل داده‌ها وجود دارد. همچنین، نگرانی‌های اخلاقی و حفظ حریم خصوصی باید در این رویکردها در نظر گرفته شوند تا اطمینان حاصل شود که داده‌ها به درستی و با احترام به حقوق بیماران استفاده می‌شوند.

۲.۱ مقدمه‌ای بر یادگیری ماشین

یادگیری ماشین یکی از پرمخاطب‌ترین حوزه‌های علوم کامپیوتر و هوش مصنوعی است که به بررسی روش‌ها و الگوریتم‌هایی می‌پردازد که از داده‌ها و تجربیات گذشته استفاده کنند و به‌طور خودکار از تجربه‌ها یاد بگیرند تا بتوانند پیش‌بینی‌ها و تصمیم‌هایی را انجام دهند. این رشته، با ترکیب اصول آماری، مبانی ریاضی و الگوریتم‌های پیچیده، به کامپیوترها امکان می‌دهد که از داده‌ها یاد بگیرند و الگوهایی را شناسایی کنند تا به طور خودکار به مسائل و وظایف مختلف پاسخ دهند.

هدف اصلی یادگیری ماشین، تعیین یک مدل یا تابعی است که با استفاده از داده‌های ورودی، بتواند به‌طور دقیق پیش‌بینی‌ها و تصمیم‌هایی را انجام دهد. در فرآیند یادگیری ماشین، ابتدا داده‌های ورودی (نمونه‌ها) به ماشین داده می‌شوند و همراه با خروجی مطلوب (برچسب یا نتیجه) آن‌ها ذخیره می‌شوند. سپس ماشین با استفاده از این داده‌ها و با تکیه بر روش‌های محاسباتی و آماری، الگوها و قواعد مختلف را در داده‌ها شناسایی می‌کند و یاد می‌گیرد. در نهایت، با داشتن مدل یادگرفته‌شده، ماشین قادر به پیش‌بینی و تصمیم‌گیری برای داده‌های جدید است.

یادگیری ماشین به دلیل قابلیت‌ها و کاربردهای گسترده‌ای که دارد، در زمینه‌های مختلفی مورد استفاده قرار می‌گیرد. از جمله کاربردهای اصلی آن می‌توان به تشخیص الگوها و اشیاء، ترجمه ماشینی، پردازش زبان طبیعی، تصویربرداری پزشکی، خودروهای هوشمند، تجزیه و تحلیل اقتصادی و مالی، بازی‌های رایانه‌ای و بسیاری دیگر اشاره کرد.

۱.۲.۱ تفاوت یادگیری ماشین با یادگیری عمیق و شبکه‌های عصبی

ابهام‌ها و تفاوت‌های میان یادگیری عمیق، یادگیری ماشینی و شبکه‌های عصبی می‌تواند برای افراد جدید در زمینه هوش مصنوعی گیج‌کننده باشد. در اینجا می‌خواهیم به وضوح تفاوت‌ها را توضیح دهیم تا ابهامات از بین بروند.

یادگیری ماشین، یادگیری عمیق و شبکه‌های عصبی، همگی زیرمجموعه‌های هوش مصنوعی هستند، اما در ارتباط با یکدیگر، تفاوت‌های گوناگونی وجود دارد. اصطلاح "یادگیری ماشین" به تکنیک‌ها و الگوریتم‌هایی اشاره دارد که ماشین‌ها را قادر می‌سازند تا از تجربه‌ها و داده‌های ورودی خود، یاد بگیرند و کارایی بهتری داشته باشند. این نوع یادگیری به دو دسته اصلی تقسیم می‌شود: یادگیری با نظارت و بدون نظارت. در یادگیری با نظارت، داده‌های برچسب‌گذاری شده برای آموزش ماشین استفاده می‌شوند، در حالی که در یادگیری بدون نظارت، ماشین تلاش می‌کند الگوها و ساختارها را به صورت خودکار از داده‌ها استخراج کند. این روش باعث کاهش وابستگی به مجموعه‌های داده برچسب‌گذاری شده می‌شود و اجازه می‌دهد تا از داده‌های بزرگتری استفاده شود.

در مقابل، یادگیری عمیق به عنوان یک زیرمجموعه از شبکه‌های عصبی تعریف می‌شود. شبکه‌های

عصبی یا شبکه‌های عصبی مصنوعی^۹، ساختارهایی هستند که به تقلید از ساختار مغز انسان برای پردازش اطلاعات و تصمیم‌گیری مشابه انسانی ایجاد شده‌اند. این شبکه‌ها از لایه‌های متعددی از نورون‌ها تشکیل شده‌اند که به یکدیگر به صورت مصنوعی متصل هستند. هر گره یا نورون مصنوعی، مقادیر ورودی را با وزن‌های مرتبط با خود ترکیب کرده و خروجی را تولید می‌کند. شبکه‌های عصبی توانایی تشخیص الگوها و ویژگی‌های پنهان در داده‌ها را دارند و این ویژگی‌ها را می‌توانند به صورت خودکار از داده‌های آموزشی استخراج کنند. تعداد لایه‌ها در این شبکه‌ها می‌تواند معیاری برای تعیین "عمیق" بودن آن‌ها باشد. اگر یک شبکه عصبی بیش از سه لایه داشته باشد (شامل لایه ورودی و خروجی)، به عنوان یک شبکه عمیق تلقی می‌شود. اما اگر شبکه‌ای تنها سه لایه داشته باشد، به عنوان یک شبکه عصبی پایه‌ای در نظر گرفته می‌شود. در نتیجه، یادگیری عمیق به عنوان یک زیرمجموعه از یادگیری ماشین و شبکه‌های عصبی، توانایی استخراج ویژگی‌ها و الگوها از داده‌ها را دارد و به این ترتیب به یک "یادگیری ماشین" تبدیل شده است که از مزایای بیشتری در مقایسه با روش‌های غیر عمیق برخوردار است. به عبارت دیگر، یادگیری عمیق امکان پردازش داده‌های بزرگتر و پیچیده‌تر را با کمترین نیاز به مداخله انسانی فراهم می‌کند و نقش بسیار مهمی در پیشرفت‌های اخیر هوش مصنوعی داشته است.

۲.۲.۱ روند کار یادگیری ماشین

دانشگاه UC Berkeley روند کار یادگیری ماشین را به سه بخش اصلی تقسیم می‌کند:

۱. پردازش تصمیم: به طور کلی، الگوریتم‌های یادگیری ماشین برای پیش‌بینی یا طبقه‌بندی استفاده می‌شوند. بر اساس داده‌های ورودی ممکن است برچسب‌گذاری شده یا برچسب‌گذاری نشده باشد و الگوریتم به صورت خودکار برآوردی درباره الگوی موجود در داده‌ها ارائه می‌دهد.
۲. تابع خطا: تابع خطا، پیش‌بینی مدل را ارزیابی می‌کند. اگر مثال‌های معتبری وجود داشته باشد، تابع خطا مقایسه‌ای انجام می‌دهد تا دقت مدل را ارزیابی کند.
۳. فرآیند بهینه‌سازی مدل: اگر پیش‌بینی‌های مدل بتواند بیشتر به نقاط داده‌ها در مجموعه آموزش نزدیک شود، آنگاه وزن‌ها به‌روزرسانی می‌شوند تا اختلاف بین مثال معتبر و برآورد مدل کاهش یابد. الگوریتم این فرآیند را تکرار می‌کند و وزن‌ها را به صورت خودکار به‌روز می‌کند تا حد دقت مورد نظر به دست آید.

۳.۲.۱ روش‌های یادگیری ماشین

در اینجا به سه دسته اصلی متدهای یادگیری ماشین، یعنی یادگیری با نظارت، یادگیری بدون نظارت و یادگیری نیمه‌نظارتی، می‌پردازیم.

⁹Artificial Neural Networks

یادگیری با نظارت

در یادگیری با نظارت^{۱۰} مدل با استفاده از مجموعه داده برچسب‌گذاری شده آموزش می‌بیند. هدف این روش، یافتن رابطه‌ای بین ورودی‌ها و خروجی‌ها است به طوری که با ورودی جدید، خروجی دقیقی تولید شود. برای این منظور، مدل با وزن‌هایی شروع به کار می‌کند و این وزن‌ها با تکرار فرآیند آموزش و تطبیق با داده‌ها، به‌طور خودکار تنظیم می‌شوند. الگوریتم‌های معروف یادگیری با نظارت شامل شبکه‌های عصبی، بیز، رگرسیون خطی، رگرسیون لجستیکی، جنگل تصادفی و ماشین بردار پشتیبانی می‌شوند.

یادگیری بدون نظارت

در یادگیری بدون نظارت^{۱۱}، مدل‌های یادگیری ماشین برای تجزیه و تحلیل و خوشه‌بندی مجموعه‌های داده بدون نیاز به برچسب‌گذاری استفاده می‌شوند. مجموعه داده در این روش شامل ورودی‌ها بدون هیچ خروجی مرتبط است. هدف این روش، کشف الگوها، شباهت‌ها و تفاوت‌ها در داده‌ها بدون تعیین موضوع یا کلاس مشخصی است. از مزایای یادگیری بدون نظارت، استفاده در تجزیه و تحلیل‌های اکتشافی داده، استراتژی‌های فروش متقابل، تقسیم‌بندی مشتریان، تشخیص تصاویر و الگوها، و همچنین کاهش تعداد ویژگی‌ها در یک مدل از طریق فرآیند کاهش بعد است. الگوریتم‌های معروف یادگیری بدون نظارت شامل شبکه‌های عصبی، خوشه‌بندی k-means و روش‌های خوشه‌بندی احتمالی می‌شوند.

یادگیری نیمه‌نظارتی

یادگیری نیمه‌نظارتی^{۱۲} روشی است که میان یادگیری با نظارت و یادگیری بدون نظارت قرار دارد. در این روش، از مجموعه‌ای کوچک از داده‌های برچسب‌گذاری شده برای هدایت فرآیند یادگیری و استخراج ویژگی از مجموعه‌ی بزرگتری از داده‌ها بدون برچسب استفاده می‌شود. این روش مشکل عدم وجود داده‌های برچسب‌گذاری شده کافی برای یادگیری با نظارت را حل می‌کند و همچنین در مواردی که برچسب‌گذاری داده‌ها هزینه‌بر است، مفید است.

¹⁰Supervised Machine Learning

¹¹Unsupervised Machine Learning

¹²Semi-supervised Machine Learning

۴.۲.۱ الگوریتم‌های رایج یادگیری ماشین

تعدادی از الگوریتم‌های یادگیری ماشین که به طور متداول استفاده می‌شوند، عبارتند از:

شبکه‌های عصبی: شبکه‌های عصبی شبیه به عملکرد مغز انسان هستند که شامل تعداد زیادی نورون پردازشی مرتبط با یکدیگر هستند. شبکه‌های عصبی در تشخیص الگوها با دقت بالایی عمل می‌کنند و نقش مهمی در برنامه‌هایی نظیر ترجمه زبان طبیعی، تشخیص تصاویر، تشخیص گفتار و ایجاد تصاویر ایفا می‌کنند.

رگرسیون خطی: این الگوریتم برای پیش‌بینی مقادیر عددی بر اساس رابطه خطی بین مقادیر مختلف استفاده می‌شود. به عنوان مثال، این تکنیک می‌تواند برای پیش‌بینی قیمت‌های خانه‌ها بر اساس داده‌های تاریخی منطقه استفاده شود.

رگرسیون لجستیک: این الگوریتم یادگیری با نظارت پاسخ‌های متغیرهای دسته‌ای را پیش‌بینی می‌کند، مانند پاسخ‌های ”بله/خیر” به سوالات. از این الگوریتم می‌توان برای کاربردهایی مانند دسته‌بندی اسپم و کنترل کیفیت در یک خط تولید استفاده کرد.

خوشه‌بندی: با استفاده از یادگیری بدون نظارت، الگوریتم‌های خوشه‌بندی می‌توانند الگوها را در داده‌ها شناسایی کنند و آن‌ها را گروه‌بندی کنند.

درخت‌های تصمیم: درخت‌های تصمیم می‌توانند برای پیش‌بینی مقادیر عددی (رگرسیون) و یا دسته‌بندی داده‌ها به دسته‌ها (کلاس‌بندی) استفاده شوند. درخت‌های تصمیم از توالی شاخه‌های تصمیمی استفاده می‌کنند که با نمودار درختی نمایش داده می‌شوند. یکی از مزایای درخت‌های تصمیم این است که آن‌ها به راحتی قابل اعتبارسنجی و بازرسی هستند.

جنگل‌های تصادفی: در جنگل‌های تصادفی، الگوریتم یادگیری ماشین با ترکیب نتایج تعدادی از درخت‌های تصمیم پیش‌بینی مقدار یا دسته‌بندی داده‌ها را انجام می‌دهد.

۳.۱ مقدمه‌ای بر شبکه‌های عصبی

یادگیری ماشین و هوش مصنوعی همواره جذابیت خاصی برای محققان و علاقه‌مندان به علوم کامپیوتر و فناوری داشته‌اند. این حوزه‌ها به طور چشمگیری به تحول و پیشرفت چشمگیری دست یافته‌اند، و یکی از مهمترین پیشرفت‌هایی که در این زمینه داشته‌ایم، توسعه و به‌کارگیری شبکه‌های عصبی مصنوعی است.

شبکه‌های عصبی، الهام گرفته از عملکرد سیستم‌های عصبی مغز انسان، یکی از قدرتمندترین و پرکاربردترین روش‌های یادگیری ماشین محسوب می‌شوند. این سیستم‌ها از تعداد زیادی از واحدهای پردازشی مصنوعی به نام "نورون‌ها" ساخته شده‌اند. ارتباطات بین این نورون‌ها مانند اتصالات مغز انسان، باعث تشکیل یک شبکه پیچیده و قدرتمند می‌شود که توانایی تشخیص الگوها، یادگیری از تجربیات گذشته و انجام عملیات پیچیده را دارد.

شبکه‌های عصبی مصنوعی از یک لایه ورودی، یک یا چند لایه پنهان و یک لایه خروجی تشکیل شده‌اند. هر گره یا نورون مصنوعی با نورون‌های دیگر ارتباط دارد و وزن و آستانه‌ای دارد. اگر خروجی هر گره به بالای مقدار آستانه‌ای تعیین شده برسد، آن گره فعال می‌شود و داده‌ها به لایه بعدی شبکه ارسال می‌شوند. در غیر این صورت، داده‌ها به لایه بعدی منتقل نمی‌شوند. شبکه‌های عصبی نیاز به داده‌های آموزشی دارند تا بتوانند از آن‌ها یاد بگیرند و دقت خود را به مرور زمان بهبود بخشند. این فرآیند به عنوان آموزش و تنظیم مدل شبکه عصبی شناخته می‌شود. با پیشرفت تکنولوژی و افزایش توان محاسباتی رایانه‌ها، امکان استفاده از شبکه‌های عصبی در حل مسائل پیچیده و چالش‌برانگیز افزایش یافته است.

۱.۳.۱ شبکه‌های عصبی چگونه کار می‌کنند؟

فرض کنید هر گره مدلی خطی را تشکیل می‌دهد که شامل داده‌های ورودی^{۱۳}، وزن‌ها^{۱۴}، یک خطای ثابت^{۱۵} و خروجی^{۱۶} است. فرمول آن به شکل زیر است:

$$\sum w_i x_i + \text{bias} = w_1 x_1 + w_2 x_2 + w_3 x_3 + \text{bias} \quad (۱.۱)$$

^{۱۳}Inputs

^{۱۴}Weights

^{۱۵}Bias

^{۱۶}Output

$$\begin{cases} 1 & \text{if } \sum w_{\setminus} x_{\setminus} + \text{bias} \geq 0 \\ 0 & \text{if } \sum w_{\setminus} x_{\setminus} + \text{bias} < 0 \end{cases} = f(x) = \text{output equation}$$

بعد از تعیین لایه ورودی، وزن‌ها اختصاص داده می‌شوند. این وزن‌ها به تعیین اهمیت هر متغیر داده‌شده کمک می‌کنند، به‌طوری که وزن‌های بزرگ‌تر بیشترین اثر را در خروجی نسبت به ورودی‌های دیگر دارند. سپس تمام ورودی‌ها در وزن‌های مربوطه ضرب می‌شوند و سپس جمع‌بندی می‌شوند. سپس خروجی از طریق تابع فعال‌سازی، که خروجی را تعیین می‌کند، عبور می‌کند. اگر خروجی از آستانه‌ای مشخص بزرگ‌تر شود، آن گره فعال می‌شود و داده به لایه بعدی در شبکه منتقل می‌شود. این باعث می‌شود خروجی یک گره به ورودی گره بعدی تبدیل شود. این فرآیند انتقال داده از یک لایه به لایه دیگر را به عنوان یک شبکه پیش‌رو تعریف می‌کنند. هنگامی که به دنبال موارد استفاده عملی‌تر برای شبکه‌های عصبی هستیم، مانند تشخیص یا طبقه‌بندی تصاویر، از یادگیری با نظارت یا مجموعه داده‌های برچسب‌گذاری شده برای آموزش الگوریتم استفاده می‌کنیم. در طول آموزش مدل، برای ارزیابی دقت آن از یک تابع هزینه (یا خطا) استفاده می‌کنیم. این به عنوان معادل میانگین مربعات خطا^{۱۷} شناخته می‌شود. در معادله زیر، i نمایانگر شاخص نمونه است \hat{y} نتیجه پیش‌بینی شده است y مقدار واقعی را نشان می‌دهد و m تعداد نمونه‌ها است.

$$\text{Function Cost} = \text{MSE} = \left(\frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 \right) \quad (2.1)$$

هدف نهایی کمینه کردن تابع هزینه^{۱۸} است تا پیش‌بینی مناسبی برای هر مشاهده فراهم شود. با تنظیم وزن‌ها و آستانه‌ها، مدل از تابع هزینه و یادگیری تقویتی برای رسیدن به نقطه همگرایی یا کمینه محلی استفاده می‌کند. فرآیندی که الگوریتم وزن‌ها را تنظیم می‌کند، توسط گرادین کاهشی^{۱۹} صورت می‌گیرد که مدل را قادر می‌سازد جهتی مناسب برای کاهش خطاها (یا کمینه کردن تابع هزینه) تعیین کند. با هر نمونه آموزش، پارامترهای مدل برای همگرایی در مقدار کمینه به‌روز رسانی می‌شوند.

بیشتر شبکه‌های عصبی عمیق به عنوان شبکه‌های پیش‌رو^{۲۰} شناخته می‌شوند، به این معنی که اطلاعات در آنها در یک سمت، از ورودی به خروجی، جریان می‌یابند. با این حال، می‌توان مدل را از طریق عملیات پس‌انتشار^{۲۱} نیز آموزش داد؛ به این معنی که از خروجی به ورودی حرکت

¹⁷MSE


¹⁸Cost Function

¹⁹Gradient Descent

²⁰Feedforward Networks

²¹Backpropagation

کرد.



شکل ۱.۱: نقطه کمینه در تابع هزینه [۲۱]

۲.۳.۱ انواع شبکه‌های عصبی

شبکه‌های عصبی می‌توانند به انواع مختلفی تقسیم شوند که برای اهداف مختلف مورد استفاده قرار می‌گیرند. هر چند این فهرست کامل نیست، اما موارد ذکر شده انواع شایع شبکه‌های عصبی هستند که برای موارد کاربردی متداول مورد استفاده قرار می‌گیرند:

پرسپترون: پرسپترون قدیمی‌ترین شبکه عصبی است که توسط فرانک روزنبلات^{۲۲} در سال ۱۹۵۸ ایجاد شد.

شبکه‌های عصبی چند لایه^{۲۳}: این شبکه‌ها شامل لایه‌های ورودی، لایه‌های مخفی و لایه خروجی هستند. مهم است بدانید که در این شبکه‌ها از نورون‌های سیگموئید استفاده می‌شود و نه از پرسپترون‌ها؛ زیرا بیشتر مسائل واقعی غیرخطی هستند. این شبکه‌ها معمولاً

^{۲۲}Frank Rosenblatt

^{۲۳}Multi Layer perceptron

از داده‌ها برای آموزش خود استفاده می‌کنند و اساس کارهایی نظیر بینایی ماشین، پردازش زبان طبیعی و سایر شبکه‌های عصبی هستند.

شبکه‌های عصبی پیچشی^{۲۴} : این شبکه‌ها به شبکه‌های پیشرو شباهت دارند، اما معمولاً برای تشخیص تصاویر، تشخیص الگو و/یا بینایی ماشین استفاده می‌شوند. این شبکه‌ها اصول جبر خطی، به ویژه ضرب ماتریسی، را به کار می‌برند تا الگوهای مختلف را در تصاویر شناسایی کنند.

شبکه‌های عصبی بازگشتی^{۲۵} : این الگوریتم‌های یادگیری به دلیل حلقه‌های بازخوردی خود شناخته می‌شوند. این شبکه‌ها اصطلاحاً زمانی مورد استفاده قرار می‌گیرند که از داده‌های سری زمانی برای پیش‌بینی نتایج آینده، مانند پیش‌بینی بازار سهام یا پیش‌بینی فروش، استفاده می‌شود.

²⁴Convolutional Neural Networks

²⁵Recurrent Neural Network

۴.۱ مقدمه‌ای بر پردازش سیگنال

پردازش سیگنال یکی از حوزه‌های مهم در علم مهندسی برق و علوم کامپیوتر است که به بررسی و تحلیل سیگنال‌ها می‌پردازد. سیگنال‌ها به عنوان تغییرات یا الگوهای از زمان، فضا یا هر دو، در داده‌ها یا اطلاعات مورد استفاده قرار می‌گیرند. این سیگنال‌ها می‌توانند از انواع مختلفی، از جمله سیگنال‌های صوتی، تصویری، زیست پزشکی، رادار، تلویزیونی، و ارتباطاتی باشند. هدف اصلی پردازش سیگنال، استخراج اطلاعات مفهومی از داده‌های سیگنالی و بهبود کیفیت یا کارایی سیگنال‌ها است. در این حوزه، از مفاهیم ریاضی و الگوریتم‌های پردازش سیگنال استفاده می‌شود تا سیگنال‌ها را تحلیل کرده و خروجی مفهومی از آن‌ها بدست آورد. پردازش سیگنال از دو نوع اصلی استفاده می‌کند: پردازش سیگنال آنالوگ و پردازش سیگنال دیجیتال. در پردازش سیگنال آنالوگ، سیگنال به صورت پیوسته در زمان و یا فضا قابل مشاهده است، در حالی که در پردازش سیگنال دیجیتال، سیگنال به صورت گسسته نمونه‌برداری شده و به شکل دیجیتال (اعداد و رشته‌های باینری) بیان می‌شود. استفاده از پردازش سیگنال در زمینه‌های مختلف بسیار گسترده است. در صنایع مختلف مانند ارتباطات، پزشکی، پردازش تصویر و صوت، اندازه‌گیری‌ها، رادار و سیستم‌های کنترل، از پردازش سیگنال بهره‌برداری می‌شود. در اینجا، به مفاهیم اصلی پردازش سیگنال، روش‌ها و الگوریتم‌های استفاده‌شده و نحوه کاربرد آن در برخی از صنایع مهم اشاره خواهیم کرد.

۱.۴.۱ مفاهیم اصلی پردازش سیگنال

۱. **سیگنال‌ها:** سیگنال‌ها تغییرات یا الگوهای از زمان، فضا یا هر دو هستند که اطلاعات مفهومی را انتقال می‌دهند. این سیگنال‌ها می‌توانند از نوع‌های مختلفی باشند از جمله سیگنال‌های صوتی، تصویری، الکترونیکی، زیست پزشکی^{۲۶} و غیره.
۲. **پردازش سیگنال آنالوگ و دیجیتال:** پردازش سیگنال‌ها به دو صورت آنالوگ و دیجیتال انجام می‌شود. در پردازش سیگنال آنالوگ، سیگنال به صورت پیوسته در زمان و فضا مورد بررسی قرار می‌گیرد، در حالی که در پردازش سیگنال دیجیتال، سیگنال به صورت گسسته نمونه‌برداری شده و به صورت اعداد و رشته‌های باینری بیان می‌شود.
۳. **فیلترها:** فیلترها یکی از مهم‌ترین ابزارهای پردازش سیگنال هستند. این ابزارها به کمک محاسبات ریاضی و عملیات ماتریسی، سیگنال را از جنبه‌های مختلفی تغییر می‌دهند. فیلترها می‌توانند جهت کاهش نویز، استخراج ویژگی‌ها، و تغییر فرکانس سیگنال‌ها مورد استفاده قرار بگیرند.

²⁶Biomedical

۴. **تبدیلات سیگنال:** تبدیلات سیگنال عملیاتی هستند که باعث تغییر شکل یا مختصات سیگنال می‌شوند. به عنوان مثال، تبدیل فوری^{۲۷} یک تبدیل مهم است که سیگنال‌های زمانی را به دامنه فرکانس تبدیل می‌کند و اطلاعات مهمی درباره ترکیب فرکانس‌ها ارائه می‌دهد.

۵. **تبدیل‌های موجک:** تبدیل‌های موجک ابزارهایی هستند که سیگنال‌ها را به شکل‌های موجی تجزیه می‌کنند. این تبدیل‌ها به ویژه در تحلیل سیگنال‌های با خصوصیات زمانی مختلف کاربرد دارند، مانند سیگنال‌های صوتی و سیگنال‌های زمانی-فرکانسی.

۶. **فیلترهای موجک:** فیلترهای موجک ابزارهایی هستند که با استفاده از تبدیل‌های موجک، فیلترهایی با خصوصیات زمانی-فرکانسی می‌سازند. این فیلترها به ویژه در تحلیل سیگنال‌ها با ساختارهای غیرخطی و غیرثابت مفهومی استفاده می‌شوند.

۷. **تشخیص الگو:** تشخیص الگویی از کاربردهای مهم پردازش سیگنال است که به تشخیص الگوها و ساختارهای خاص در سیگنال‌ها می‌پردازد. این کاربرد به ویژه در تشخیص چهره و اثر انگشت، تشخیص ماشینی، تشخیص سرطان و بسیاری دیگر از مسائل کاربرد دارد.

۲۰۴۰۱ روش‌ها و الگوریتم‌های پردازش سیگنال

در پردازش سیگنال، برای حل مسائل و تحلیل داده‌ها از مجموعه‌ای از روش‌ها و الگوریتم‌ها استفاده می‌شود که به تحلیل و تبدیل سیگنال‌ها کمک می‌کنند. این الگوریتم‌ها معمولاً بر اساس ریاضیات و آمار توسعه داده شده‌اند و به ویژه در مسائل پیچیده و سیگنال‌های بزرگ، نقش بسزایی ایفا می‌کنند. در زیر به برخی از روش‌ها و الگوریتم‌های مهم در پردازش سیگنال اشاره می‌کنیم:

۱. **تبدیل فوری:** تبدیل فوری یکی از ابزارهای مهم در پردازش سیگنال است که سیگنال‌ها را از دامنه زمان به دامنه فرکانس تبدیل می‌کند. تبدیل فوری به تحلیل طیف فرکانسی سیگنال‌ها کمک می‌کند و کاربردهای زیادی در مواردی مانند فیلترهای فرکانسی، ضبط و پخش صوت، تشخیص الگو و ... دارد.

۲. **فیلترها:** فیلترها برای تغییر طیف فرکانسی و زمانی سیگنال‌ها استفاده می‌شوند. فیلترها می‌توانند پایین‌گذر، بالاگذر، باندگذر یا باندمتوازن باشند و به تحلیل و تغییر سیگنال‌ها در دامنه‌های مختلف کمک می‌کنند.

۳. **تحلیل موجک:** تحلیل موجک مجموعه‌ای از روش‌ها برای تجزیه سیگنال‌ها به امواج کوچکتر است که برای تحلیل سیگنال‌های غیرخطی و با خصوصیات زمانی-فرکانسی استفاده می‌شود.

²⁷Fourier transform

۴. **الگوریتم‌های بافته‌سازی**^{۲۸} : الگوریتم‌های بافته‌سازی معمولاً برای بازسازی تصاویر و سیگنال‌ها با کاهش نویز و حذف اجزای غیرضروری استفاده می‌شوند.

۵. **تحلیل کرنل**: تحلیل کرنل یکی از روش‌های مورد استفاده در تحلیل سیگنال‌ها است که به تشخیص و تحلیل الگوها و روابط موجود در سیگنال‌ها کمک می‌کند.

۶. **تحلیل زمان-فرکانس**: در بسیاری از کاربردهای سیگنال‌ها، خصوصیات زمان-فرکانسی مهم هستند. تحلیل زمان-فرکانس با استفاده از تبدیل‌ها و الگوریتم‌های مختلف، به تحلیل و استخراج اطلاعات از این نوع سیگنال‌ها می‌پردازد.

۷. **روش‌های آماری**: در پردازش سیگنال، روش‌های آماری مانند کماتش مؤلفه‌ها^{۲۹} و تحلیل کانونی^{۳۰} نیز به عنوان روش‌های کمکی استفاده می‌شوند.

این لیست تنها یک نمونه کوچک از روش‌ها و الگوریتم‌های استفاده‌شده در پردازش سیگنال است. در هر زمینه‌ای از پردازش سیگنال، الگوریتم‌ها و روش‌های مختلفی می‌توانند برای حل مسائل و تحلیل داده‌ها به کار گرفته شوند.

²⁸Texture Synthesis Algorithms

²⁹PCA

³⁰CCA

فصل ۲

مدل ها

در این بخش از پژوهش، ما از چندین مدل مختلف برای طبقه‌بندی اختلال‌های عصبی با استفاده از QEEG استفاده کردیم. این مدل‌ها شامل مدل‌های خطی و غیرخطی با روش‌های مختلفی بودند. مدل‌هایی که استفاده کردیم به شرح زیر هستند:

۱. مدل رگرسیون لجستیک^۱ با ترکیب الاستیک^۲: در این مدل از روش رگرسیون لجستیک با ترکیب الاستیک استفاده شد. این مدل برای طبقه‌بندی داده‌ها به شکل خطی کاربرد دارد و به ویژه برای مواجهه با مشکل انتخاب ویژگی‌های مهم در داده‌های با ابعاد بالا مفید است.

۲. مدل ماشین بردار پشتیبان^۳ با هسته خطی: ما از مدل ماشین بردار پشتیبان با هسته خطی استفاده کردیم تا بتوانیم به ویژگی‌های مهم در داده‌ها دسترسی داشته باشیم. این مدل برای طبقه‌بندی داده‌ها در فضای مختلط کاربرد دارد و از دقت بالایی برخوردار است.

۳. مدل جنگل تصادفی^۴: این مدل از روش جنگل تصادفی برای طبقه‌بندی داده‌ها استفاده می‌کند. جنگل تصادفی یک مدل غیرخطی است که از ترکیب چندین درخت تصمیم استفاده می‌کند تا به دقت بالایی در طبقه‌بندی داده‌ها دست یابد.

برای هر یک از مدل‌ها، از روش اعتبارسنجی متقابل^۵ و جستجوی خطی^۶ برای پیدا کردن بهترین پارامترهای مدل‌ها، دقت و عملکرد هر مدل استفاده شده است.

¹Logistic Regression

²ElasticNet

³Support Vector Machine

⁴Random Forest

⁵Cross-validation

⁶Grid Search

۱.۲ مدل رگرسیون لجستیک


رگرسیون لجستیک یکی از پرکاربردترین الگوریتم‌های حوزه‌ی یادگیری ماشین است که در اوایل قرن بیستم در علوم زیستی مورد مطالعه قرار گرفت و پس از آن در بسیاری از کاربردهای علوم اجتماعی استفاده شد. این تکنیک یک روش یادگیری تحت نظارت است و در آن داده‌ها دارای برچسب مشخص هستند.

تابع رگرسیون لجستیک به صورت زیر تعریف می‌شود:

$$h_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \quad (۱.۲)$$

در این رابطه، x برداری از ویژگی‌های ورودی است، θ برداری از پارامترهای مدل، σ تابع سیگموئید است، و $h_{\theta}(x)$ نشان‌دهنده‌ی احتمال تخمینی مدل برای برچسب مثبت برای داده ورودی x با پارامترهای θ است. تابع سیگموئید $\sigma(z)$ به صورت زیر تعریف می‌شود:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (۲.۲)$$



شکل ۱.۲: تابع سیگموئید [۲۲]

که در آن $z = \theta^T x$ مجموع وزن‌های ویژگی‌های ورودی و پارامترهای مدل است. تابع سیگموئید هر مقدار z را به مقداری بین ۰ و ۱ نگاشت می‌کند که می‌تواند به عنوان احتمال تعبیر شود.

در این پایان‌نامه، از ElasticNet در رگرسیون لجستیک استفاده شده. برای ترکیب رگرسیون لجستیک با روش ElasticNet، لازم است که تابع هزینه استاندارد رگرسیون لجستیک را با افزودن جریمه ElasticNet regularization تغییر دهیم. تابع هزینه اصلاح شده به شکل زیر نوشته می‌شود:

$$(۳.۲) \\ J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \log(1-h_{\theta}(x^{(i)}))] + \lambda_1 \sum_{j=1}^n |\theta_j| + \lambda_2 \sum_{j=1}^n \theta_j^2$$


در این رابطه، بخش اول تابع هزینه، تابع هزینه رگرسیون لجستیک استاندارد است که اختلاف بین احتمال‌های پیش‌بینی شده و برچسب‌های واقعی را اندازه‌گیری می‌کند. بخش دوم و سوم به ترتیب جریمه‌های L1 و L2 هستند. λ_1 و λ_2 پارامترهای regularization هستند که قدرت جریمه L1 و L2 را کنترل می‌کنند.

۲.۲ مدل ماشین بردار پشتیبان:

ماشین بردار پشتیبان یک الگوریتم یادگیری ماشین نظارتی است که نمونه‌ی داده‌هایی را به صورتی نقاطی در فضا نشان داده شده است، با استفاده از یک خط یا ابر صفحه^۷، از هم جدا می‌کند. این جداسازی به گونه‌ای است که نقاط داده‌ای که در یک طرف خط هستند مشابه هم و در یک گروه قرار می‌گیرند. نمونه داده‌های جدید هم بعد از اضافه شدن به همان فضا در یکی از دسته‌های موجود قرار خواهند گرفت.

ممکن است تعداد ابر صفحه‌هایی که کلاس‌ها را از هم جدا می‌کنند بیشتر از یک باشد که در این صورت در تلاش برای پیدا کردن ابر صفحه‌ای هستیم که حداکثر فاصله را با نقاط هر دو کلاس داشته باشد.

⁷Hyperplane



شکل ۲.۲: ماشین بردار پشتیبان [۲۳]

بخش بهینه‌سازی در SVM شامل یافتن مقادیر بهینه پارامترهای مدل است که بتوانند بهترین جداسازی بین دو کلاس را انجام دهند. تابع هدف به شکل زیر تعریف می‌شود:

$$\frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

در این فرمول، \mathbf{w} بردار وزن، n تعداد نمونه‌های آموزش، ξ_i متغیر اضافه مربوط به نمونه آموزشی i ام و C یک پارامتر مهم است که تعادل بین بالا بردن حاشیه و کمینه کردن خطا را کنترل می‌کند. حاشیه فاصله بین هایپرپلین و نزدیک‌ترین نقاط داده‌ها از هر کلاس است. محدودیت‌ها در SVM به شکل زیر تعریف می‌شوند:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

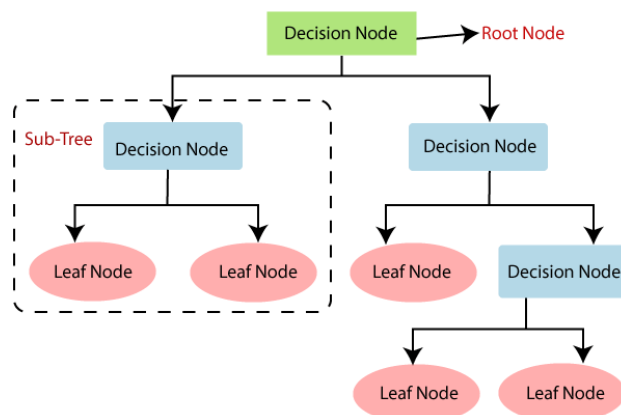
$$\xi_i \geq 0$$

در این فرمول، y_i برچسب کلاس نمونه i ام، \mathbf{x}_i بردار ویژگی نمونه i ام، b مقدار انحراف و ξ_i متغیر اضافه مربوط به نمونه آموزشی i ام هستند. برای حل این مسئله بهینه‌سازی، از روش‌های مختلفی مانند کاهش گرادیان استفاده می‌شود. این روش‌ها به صورت تکراری بردار وزن و انحراف را به‌روزرسانی می‌کنند تا به مقدار بهینه برسند.

۳.۲ مدل جنگل تصادفی

مدل جنگل تصادفی یکی از رایج‌ترین و محبوب‌ترین روش‌های یادگیری ماشین است که برای مسائل مختلف از جمله دسته‌بندی و رگرسیون استفاده می‌شود. این مدل از تکنیکی به نام ترکیب

مدل‌ها^۸ استفاده می‌کند تا از مزایای تعدادی از مدل‌های ضعیف، به طور مثال درخت‌های تصمیم یا تصمیم‌گیرهای ماشینی ساده، بهره ببرد و به شکل یک مدل قوی‌تر عمل کند. درخت تصمیم^۹، همانطور که از نامش پیداست، یک ساختار شاخه‌ای است که برای تصمیم‌گیری استفاده می‌شود. درخت تصمیم با تجمع اطلاعات بدست آمده از ویژگی‌ها، داده‌ها را به دسته‌ها با برجسب‌های مختلف تقسیم می‌کند. درخت‌های تصمیم به تنهایی ممکن است بهترین کارایی را نداشته باشند و به مشکلاتی مانند بایاس و برازش بیش از حد^{۱۰} دچار شوند. با این حال، وقتی چندین درخت تصمیم در الگوریتم جنگل تصادفی تشکیل یک مجموعه^{۱۱} می‌دهند، نتایج دقیق‌تر پیش‌بینی می‌شوند به خصوص زمانی که درخت‌ها با یکدیگر همبسته^{۱۲} نیستند.



شکل ۳.۲: درخت تصمیم [۲۴]

الگوریتم جنگل تصادفی از دو مرحله تشکیل شده است؛ در مرحله اول، جنگل تصادفی با ترکیب N درخت تصمیم ساخته می‌شود و در مرحله دوم، عمل پیش‌بینی برای هر کدام از درختانی که در مرحله اول ایجاد شده بودند، انجام می‌شود.

^۸Ensemble Learning

^۹Decision tree

^{۱۰}Overfitting

^{۱۱}Ensemble

^{۱۲}Correlated

الگوریتم کلی این مدل به صورت زیر است:

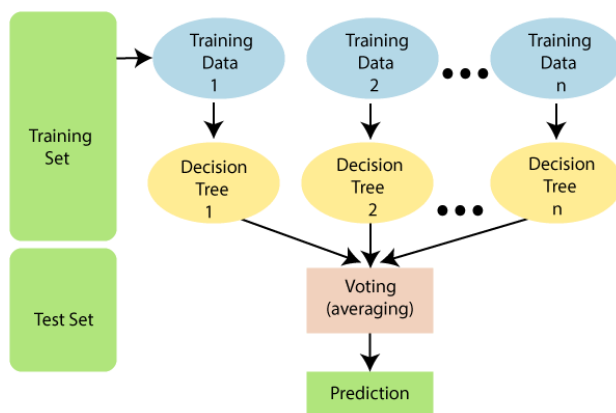
مرحله ۱: K نقطه تصادفی از مجموعه داده‌گان آموزشی انتخاب کنید.

مرحله ۲: درخت‌های تصمیم را برای هر کدام از نقاط انتخاب شده که در واقع زیر مجموعه داده‌گان کل هستند، بسازید.

مرحله ۳: N درخت تصمیم را برای ارزیابی نهایی انتخاب کنید.

مرحله ۴: مراحل ۱ و ۲ را تکرار کنید.

مرحله ۵: برای نقاط جدید، پیش‌بینی‌های هر درخت تصمیمی را پیدا کرده و نقاط جدید را به دسته‌بندی اختصاص دهید که بهترین عملکرد را داشته.



شکل ۴.۲: الگوریتم جنگل تصادفی [۲۴]

از مزایای مدل جنگل تصادفی می‌توان به موارد زیر اشاره کرد:

- امکان پردازش داده‌های بزرگ و متنوع با کارایی مناسب.
- قابلیت مقابله با برازش بیش از حد و ارائه عملکرد خوب برای داده‌های جدید.

فصل ۳

نتایج

۱.۳ داده ها

۱.۱.۳ جمع‌آوری داده‌ها

داده‌های استفاده شده از مقاله Park et al. گردآوری شدند [۲۸]. این مقاله معیارهای ارزیابی، نتایج QEEG و پرونده‌های پزشکی بیماران بالینی را از ژانویه ۲۰۱۱ تا دسامبر ۲۰۱۸ از مرکز پزشکی Boramae در سئول، کره جنوبی شامل می‌شود. همچنین نمونه‌های کنترل سالم نیز از تحقیقات انجام شده در همین مرکز انتخاب و به داده‌ها اضافه شده.

در این مطالعه، تشخیص بیماران بالینی توسط یک روانپزشک بر اساس معیارهای DSM-IV یا DSM-5 انجام شد. همچنین، از مصاحبه بین‌المللی عصب‌روانشناختی کوتاه^۱ نیز در ارزیابی‌های روانشناختی استفاده شد. تایید بالینی نهایی تشخیص اصلی، توسط دو روانپزشک و دو روانشناس انجام شد. آنها بررسی کردند که تشخیص‌های اصلی در پرونده‌های پزشکی الکترونیکی و ارزیابی‌های روانشناختی که ۱ ماه قبل و بعد از QEEG تکمیل شده باشند.

نمونه داده‌های مطالعه شامل ۹۴۵ فرد بود، که برای جزئی از مطالعه بودن باید معیارهای مشخصی را می‌داشتند. این معیارها شامل سن افراد در بازه ۱۸ تا ۷۰ سال، اختلالات مشخص شده که شامل شش دسته در اختلالات اصلی و نه دسته اختلالات خاص و افراد سالم تقسیم می‌شدند، بودند. همچنین این افراد می‌بایست قادر به گوش دادن، خواندن و نوشتن و به طور کلی فهم زبان کره‌ای می‌بودند.

ضوابط استثناء نیز وجود داشتند که از جمله آنها محدودیت‌هایی در سابقه پزشکی افراد اعمال می‌شد. برای مثال، افراد با سابقه اختلال عصبی یا صدمه‌ی مغزی، اختلالات عصبی-توسعی‌ای نظیر اختلال ذهنی با شاخص هوشی کمتر از ۷۰ یا عملکرد مغزی مرزی با شاخص هوشی میانه بین ۷۰ تا ۸۰، اختلال تیک یا اختلال کمبود توجه و بیش‌فعالی، و هرگونه اختلال عصبی-شناختی از

¹Mini-International Neuropsychiatric Interview

مطالعه مستثنی شدند.

به طور کلی نمونه داده ها شامل:

جدول ۱.۳: تعداد افراد در هر یک از زیرگروه‌ها

تعداد افراد	نوع بیماری
۹۵	نمونه کنترل سالم (HC)
۱۱۷	اسکیزوفرنی
۲۶۶	اختلالات خلقی
۱۱۹	اختلال افسردگی
۶۷	اختلالات دوقطبی
۱۰۷	اختلالات اضطرابی
۵۹	اختلال افسردگی
۴۸	اختلالات اضطراب اجتماعی
۴۶	اختلال وسواس - اجباری
۱۸۶	اختلالات اعتیادی
۹۳	اختلال مصرف الکل
۹۳	اعتیادهای رفتاری از جمله اعتیاد به بازی و اینترنت
۱۲۸	اختلالات مرتبط با آسیب و استرس
۵۲	اختلال استرس پس از ضربه (PTSD)
۳۸	اختلال استرس حاد
۳۸	اختلال سازگاری

این مطالعه تحت تأیید هیئت نظارت مؤسسه قرار گرفت و با توجه به طراحی بازبینی^۲، موافقت شرکت‌کنندگان برای شرکت در مطالعه اجباری نبود. اطلاعات جمع‌آوری شده از این مقاله به‌عنوان پایه‌ای قابل اطمینان و معتبر برای این گزارش در نظر گرفته شده.

۲.۱.۳ تنظیمات و پارامترهای EEG

داده‌های EEG شامل ۵ دقیقه استراحت با چشم‌ها بسته بود که با ۱۹ یا ۶۴ کانال با نرخ نمونه‌برداری ۵۰۰ تا ۱۰۰۰ هرتز و فیلتر آنالین با محدوده ۰.۱ تا ۱۰۰ از طریق Neuroscan^۳ جمع‌آوری شده. مقاومت الکترودها تا زیر ۵ کیلو اهم با استفاده از ژل سایشی و هادی الکتریکی اعمال شده. در تحلیل، داده‌های EEG به نرخ نمونه‌برداری ۱۲۸ هرتز کاهش یافته و ۱۹ کانال

^۲Retrospective Study Design

^۳Scan 4.5; Compumedics NeuroScan, Victoria, Australia

بر اساس سیستم ۱۰-۲۰ بین‌المللی همراه با الکتروود مرجع ماستوئید^۴ انتخاب شده. کانال زمین^۵ بین الکتروودهای FPz و Fz قرار گرفته شده. از سیستم Neuroguide^۶ برای تبدیل داده‌های EEG به دامنه‌ی فرکانس با استفاده از تبدیل فوریه سریع^۷ با پارامترهای زیر استفاده شده است:

جدول ۲.۳: تنظیمات و پارامترهای EEG

نرخ نمونه‌برداری	تعداد نقاط زمان دیجیتال	محدوده فرکانسی (هرتز)	دقت فرکانسی (هرتز)	پنجره زاویه‌ای
۱۲۸ نمونه بر ثانیه	۲۵۶ نقطه	۰.۵ تا ۴۰	۵.۰	cos

استفاده از پنجره زاویه‌ای کوسینوسی به منظور کاهش نشتیاز^۸ است. به دلیل عملیات ریاضیاتی تبدیل فوریه سریع، یک ایپاک زمانی به تنهایی نویزی خواهد بود، بنابراین از حداقل ۶۰ ثانیه از کل زمان استفاده شد. جزئیات پیش‌پردازش در [۱] توضیح داده شده است. در مطالعه فعلی، چگالی طیفی توان^۹ و اتصال‌ناپذیری کوهرانس^{۱۰} به عنوان پارامترهای EEG در نظر گرفته شدند. هر پارامتر EEG با باندهای فرکانسی زیر محاسبه شد:

جدول ۳.۳: باندهای فرکانسی در EEG

محدوده فرکانسی (هرتز)	باندهای فرکانسی
۱-۴	دلتا
۴-۸	تتا
۸-۱۲	آلفا
۱۲-۲۵	بتا
۲۵-۳۰	بتا بالا
۳۰-۴۰	گاما

PSD توان طیفی ای که در سطح سنسور اندازه‌گیری می‌شود است و مقدار توان مطلق در هر باند فرکانسی را شامل می‌شود. FC توسط مقدار هماهنگی نمایانگر همگام‌سازی بین دو سیگنال بر اساس پیوستگی فازی معلوم می‌شود [۲] [۳].

برای کمینه‌سازی تأثیر نوابک‌زدایی^{۱۱} در تبدیل فوریه سریع [۴]، میانگین اسلایدینگ EEG

⁴Mastoid Reference Electrode

⁵Ground Channel

⁶NG Deluxe 3.0.5 Applied Neuroscience Inc. Largo FL USA

⁷FFT

⁸leakage

⁹PSD $\mu V^2/Hz$

¹⁰FC

¹¹Windowing

از ماتریس متقاطع تبدیل فوریه سریع ۲۵۶ نقطه^{۱۲} برای هر شرکت‌کننده محاسبه شد. داده‌های EEG، با محاسبه مجدد FFT، و در ادامه با پنجره لغزشی ۶۴ نقطه‌ای از طیف متقابل فوریه سریع ۲۵۶ نقطه‌ای برای کل رکوردهای EEG تحول یافته، ویرایش شدند. میانگین، واریانس، انحراف معیار، مجموع مربعات و مجموع مربعی ضرایب حقیقی (کسینوس) و خیالی (سینوس) ماتریس متقاطع برای تمام ۱۹ کانال محاسبه شده و برای هر شرکت‌کننده تعداد کلی ۸۱ و ۱۵۳۹ عنصر تبدیل شده لگاریتمی بدست آمد. برای محاسبه هماهنگی از معادله زیر استفاده شد [۵]:

$$\text{coherence}(f) = \frac{(\sum_N (a(x)u(y) + b(x)v(y)))^2 + (\sum_N (a(x)v(y) + b(x)u(y)))^2}{\sum_N (a(x)^2 + b(x)^2) \sum_N (u(y)^2 + v(y)^2)} \quad (۱.۳)$$

متغیر	شرح
$a(x)$	ضریب کوسینوسی برای فرکانس f برای کانال x
$b(x)$	ضریب سینوسی برای فرکانس f برای کانال x
$u(y)$	ضریب کوسینوسی برای فرکانس f برای کانال y
$v(y)$	ضریب سینوسی برای فرکانس f برای کانال y

۳.۱.۳ تحلیل داده‌ها

آماره‌های توصیفی برای بررسی توزیع کلی ویژگی‌های جمعیت‌شناختی برای هر شرکت‌کننده استفاده شد. علاوه بر این، IQ یک متغیر روان‌شناختی اصلی است که ممکن است با QEEG مرتبط باشد [۶] و می‌تواند نتیجه‌ی علائم روانی (به عنوان مثال، کاهش حرکت رفتاری روان‌شناختی) محسوب شود. بنابراین، به عنوان یکی از ویژگی‌ها بررسی شده است. جدول ۴.۳ شمایی کلی از داده‌های سن، تحصیلات و IQ به ما می‌دهد.

¹²256-point FFT Cross-spectral Matrix

جدول ۴.۳: تحلیل آماری داده‌ها

	Age	Education	IQ
Count	945	930	932
Mean	30.59	13.44	101.58
Standard Deviation	11.78	2.55	17.02
Minimum	18	0	49
25th Percentile	21.73	12.00	91.00
50th Percentile (Median)	26.15	13.00	102.00
75th Percentile	35.45	16.00	114.00
Maximum	71.88	20.00	145.00

دو جدول زیر شامل آماره‌های توصیفی برای ویژگی‌های جمعیت‌شناختی و تحلیل داده‌ها بر اساس اختلال اصلی و اختلال خاص می‌باشند. در جدول ۵.۳ نتایج آماره‌های توصیفی برای سن، تحصیلات و IQ برای کلیه شرکت‌کنندگان نمایش داده شده است. در جدول ۶.۳، نتایج تحلیل داده‌ها بر اساس اختلال خاص (گروه‌های بالینی با توجه به نوع اختلال) آورده شده‌اند.

جدول ۵.۳: تحلیل آماری داده‌ها بر اساس اختلالات اصلی

Main Disorder	Age	Education	IQ	Percentage (F)	Percentage (M)
Addictive disorder	29.63	13.23	103.88	11.83%	88.17%
Anxiety disorder	29.01	13.14	98.31	26.17%	73.83%
Healthy control	25.72	14.91	116.24	36.84%	63.16%
Mood disorder	30.87	13.31	101.58	43.23%	56.77%
Obsessive compulsive disorder	28.48	13.93	107.80	17.39%	82.61%
Schizophrenia	31.73	12.84	89.62	44.44%	55.56%
Trauma and stress related disorder	36.09	13.57	98.89	65.63%	34.38%


جدول ۶.۳: تحلیل آماری داده‌ها بر اساس اختلالات جزئی

Specific Disorder	Age	Education	IQ	Percentage (F)	Percentage (M)
Acute stress disorder	28.90	14.26	104.06	92.11%	7.89%
Adjustment disorder	34.19	13.16	94.24	28.95%	71.05%
Alcohol use disorder	34.16	13.29	103.38	19.35%	80.65%
Behavioral addiction disorder	25.09	13.16	104.38	4.30%	95.70%
Bipolar disorder	29.71	14.11	100.81	37.31%	62.69%
Depressive disorder	31.26	13.05	101.85	45.23%	54.77%
Healthy control	25.72	14.91	116.24	36.84%	63.16%
Obsessive compulsive disorder	28.48	13.93	107.80	17.39%	82.61%
Panic disorder	31.05	13.45	100.31	35.59%	64.41%
Posttraumatic stress disorder	42.74	13.37	98.90	73.08%	26.92%
Schizophrenia	31.73	12.84	89.62	44.44%	55.56%
Social anxiety disorder	26.51	12.77	95.85	14.58%	85.42%


سوال مهمی که پیش می‌آید این است که آیا کلاس‌های موجود همگن هستند یا ناهمگن. طبق تصویر ۲.۳، به وضوح مشاهده می‌شود که کلاس‌ها ناهمگن هستند، به ویژه در موارد اختلال وسواسی، اختلالات خاص در دسته‌های اختلالات مرتبط با تروما و استرس و اختلالات اضطرابی و اختلال افسردگی.

شکل ۱.۳ نمایانگر نسبت جنسیت داده‌ها هست که همانطور که مشاهده می‌شود، نسبت جنسیت برابر نیست و این امر ممکن است باعث به وجود آمدن بایس و تبعیض جنسیتی بین بیماران شود. اینکه وجود صفت جنسیت برای طبقه بندی بیماری‌های عصبی ضروری باشد در این گزارش نمی‌گنجد و باید توسط متخصصان اعصاب بررسی شود.


Non Healthy Controls by Sex



Healthy Controls by Sex



Male to Female Ratio

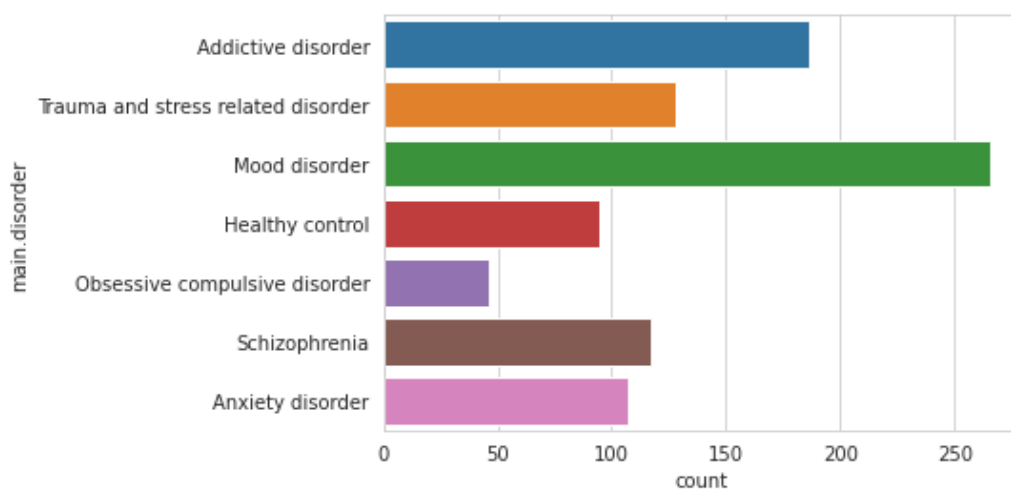


(ج) نسبت جنسیت در بیماران


(ب) نسبت جنسیت افراد سالم

(آ) نسبت جنسیت در کل داده‌ها

شکل ۱.۳: نسبت جنسیت



(آ) تعداد داده‌ها برای اختلالات اصلی




(ب) تعداد داده‌ها برای اختلالات جزئی

شکل ۲.۳: تعداد داده‌های هر کلاس


با توجه به شکل ۳.۳، متغیر IQ دارای توزیع نرمال است که به معنای آن هست که داده‌ها به طور معمول و به حالتی متوازن و همتراز قرار دارند. بنابراین، نیازی به تبدیل و تغییر فرمت نداریم و می‌توانیم آن را به همان صورتی که می‌باشد استفاده کنیم. توزیع تحصیلات تا حدی شبیه به توزیع نرمال می‌باشد، یعنی داده‌ها به صورت یکنواخت در طیف مختلف پخش می‌شوند و شکلی غیر منظم دارند. با این حال، در نظر نداریم که تغییری روی این ویژگی انجام دهیم و از آن به همان صورتی که می‌باشد استفاده خواهیم کرد. در مورد سن، ویژگی‌های PSD و FC، داده‌ها به نظر می‌آید دارای توزیع لگاریتمی-نرمال هستند، به این معنا که برای برخی از اندازه‌گیری‌ها، بهتر است از مقادیر لگاریتم آنها استفاده کنیم. این تبدیل می‌تواند به بهبود توزیع داده‌ها کمک کند و در تحلیل‌ها و مدل‌سازی‌ها مفید باشد. اگرچه این تبدیل ممکن است باعث کاهش ویژگی‌های محاسبه‌شده شود، اما می‌تواند دقت و صحت نتایج را افزایش دهد. بنابراین، باید تبدیل لگاریتمی بر روی این ویژگی‌ها اعمال شود.

شکل ۴.۳ توضیح ویژگی‌های PSD و شکل ۵.۳ توضیح ویژگی‌های FC را نشان می‌دهد.




(ب) توزیع داده در ویژگی تحصیلات

(آ) توزیع داده در ویژگی سن




(ج) توزیع داده در ویژگی IQ

شکل ۳.۳: توزیع داده ها در ویژگی های عددی



شکل ۴.۳: توزیع داده ها در ویژگی های PSD



شکل ۵.۳: توزیع داده ها در ویژگی های FC

در ادامه، به بررسی داده‌های ناقص^{۱۳} پرداخته‌ایم.

جدول ۷.۳: تعداد داده‌های ناقص

Disorder	all data	nan percentage
Obsessive compulsive disorder	46	13.04%
Addictive disorder	186	4.30%
Trauma and stress-related disorder	128	3.91%
Healthy control	95	2.11%
Mood disorder	266	1.50%
Anxiety disorder	107	0.93%

در ابتدا می‌خواهیم درصدی از داده‌ها را که دارای اطلاعات ناقص هستند را محاسبه کنیم (به‌ازای هر گروه اختلالات اصلی). می‌بینیم که اگر ردیف‌های حاوی داده‌های ناقص را حذف کنیم، درصد زیادی از داده‌ها را از دست خواهیم داد، به‌ویژه برای بیماران مبتلا به اختلال وسواسی (۱۳٪) که از کوچکترین گروه‌ها هستند. بنابراین، باید در نظر داشته باشیم که از روش‌های پر کردن داده‌های ناقص استفاده کنیم. گزینه‌های ما برای پر کردن داده‌های ناقص به شرح زیر هستند:

مقدار ویژه^{۱۴}:

در این روش، برای پر کردن داده‌های ناقص، یک مقدار ثابت و پیش‌تعیین شده به عنوان مقدار ویژه انتخاب می‌شود و به جای داده‌های ناقص قرار می‌گیرد. این روش در مواردی که مقدار ویژه مشخص و مناسب وجود داشته باشد، قابل استفاده است.

میانگین/مد مقادیر:

در این روش، برای پر کردن داده‌های ناقص، میانگین^{۱۵} یا مد^{۱۶} مقادیر موجود در داده‌ها محاسبه می‌شود و در جای داده‌های ناقص قرار می‌گیرد. این روش می‌تواند برای مقادیر پیوسته و گسسته استفاده شود و به معنای تعمیم داده‌های موجود است.

¹³Nan Data

¹⁴Special Value

¹⁵Mean

¹⁶Median

روش پیش‌بینی^{۱۷} :

در این روش، از مدل‌سازی و پیش‌بینی داده‌های ناقص با استفاده از داده‌های موجود استفاده می‌شود. به عبارت دیگر، با استفاده از الگوریتم‌ها و مدل‌های مختلف، داده‌های ناقص تخمین زده می‌شوند و با اعمال این تخمین‌ها، مقادیر ناقص پر می‌شوند. این روش به معنای ایجاد داده‌های مصنوعی و تکمیل داده‌های ناقص است.

در ادامه مقادیر ناقص را با مقدار مد پر کردیم. به این ترتیب، از میانگین داده‌ها استفاده نشد که می‌تواند تأثیر متعادل‌کننده‌ای بر روی داده‌ها داشته باشد، و به‌جاش از مد استفاده شد که مقدار متکررترین داده در میان داده‌های موجود است. زیرا این روش می‌تواند برای پر کردن داده‌های ناقص در مواردی که توزیع اصلی داده‌ها اهمیت دارد، مناسب باشد و می‌تواند تأثیری کمتر بر روی تحلیل‌ها داشته باشد.

۴.۱.۳ تصویرسازی PSD

تصویرسازی PSD^{۱۸} یکی از روش‌های معمول برای نمایش داده‌های QEEG است. در تصویرسازی PSD، معمولاً مقادیر قدرت در طیف‌های فرکانسی مختلف به صورت نمودار یا نمودارهای D2 یا D3 نشان داده می‌شوند. این نمودارها نشان‌دهنده میزان انرژی موجود در هر باند فرکانسی هستند که می‌تواند اطلاعات مفیدی ارائه دهد.

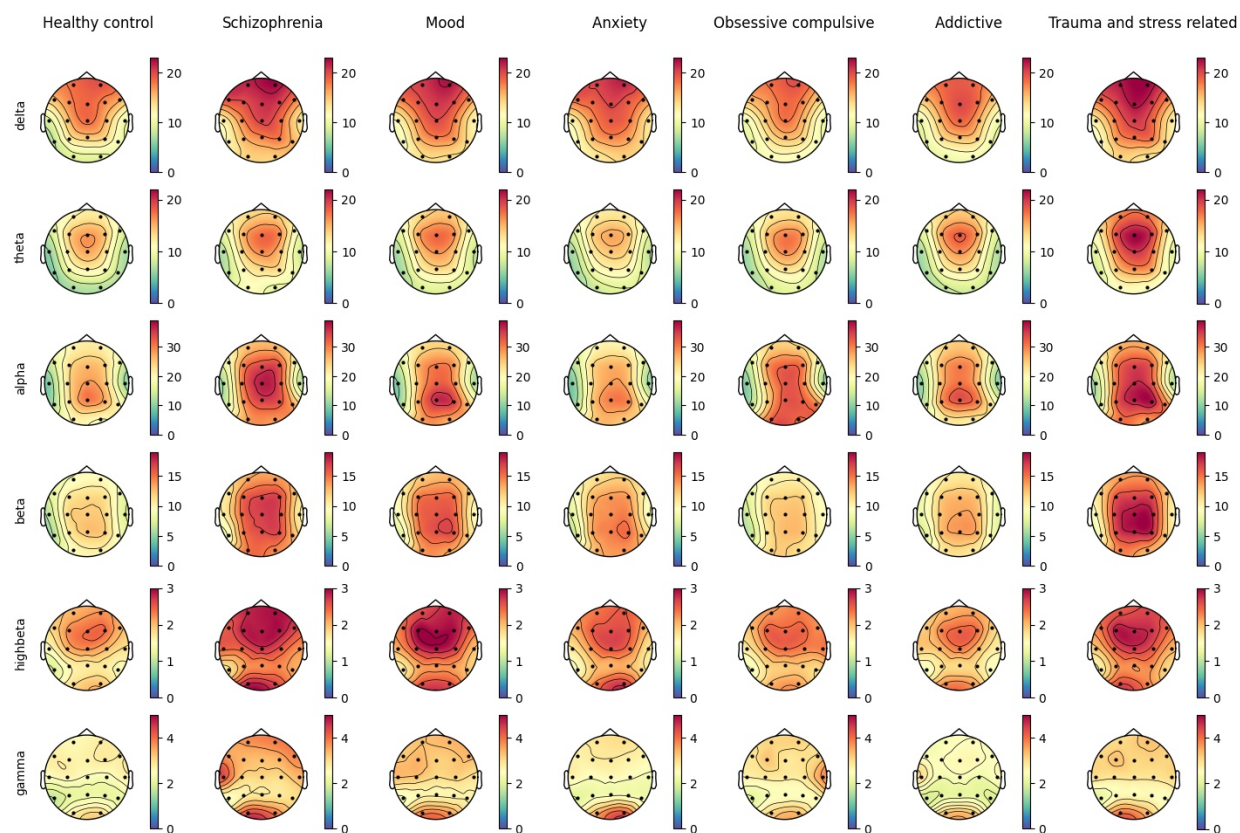
نمودارهایی که در شکل ۶.۳ و ۷.۳ نمایش داده می‌شوند، از نوع 2D هستند. این نمودارها در واقع نمایش‌های ۲ بعدی از اطلاعات فرکانسی مغز هستند. محور افقی این نمودارها نشان‌دهنده فرکانس‌ها^{۱۹} است و محور عمودی نشان‌دهنده میزان قدرت طیفی مغز^{۲۰} می‌باشد. با استفاده از این نمودارها، می‌توان میزان انرژی موجود در هر باند فرکانسی مغز را برای هر کانال به طور دقیق مشاهده کرد و مقایسه‌های مختلف بین کانال‌ها و گروه‌ها انجام داد. این اطلاعات مفیدی از نحوه توزیع فرکانس‌های مختلف مغز در مراحل مختلف و بر اساس گروه‌های مختلف بیماری‌ها را ارائه می‌دهد.

¹⁷Imputation

¹⁸Power Spectral Density

¹⁹Hz

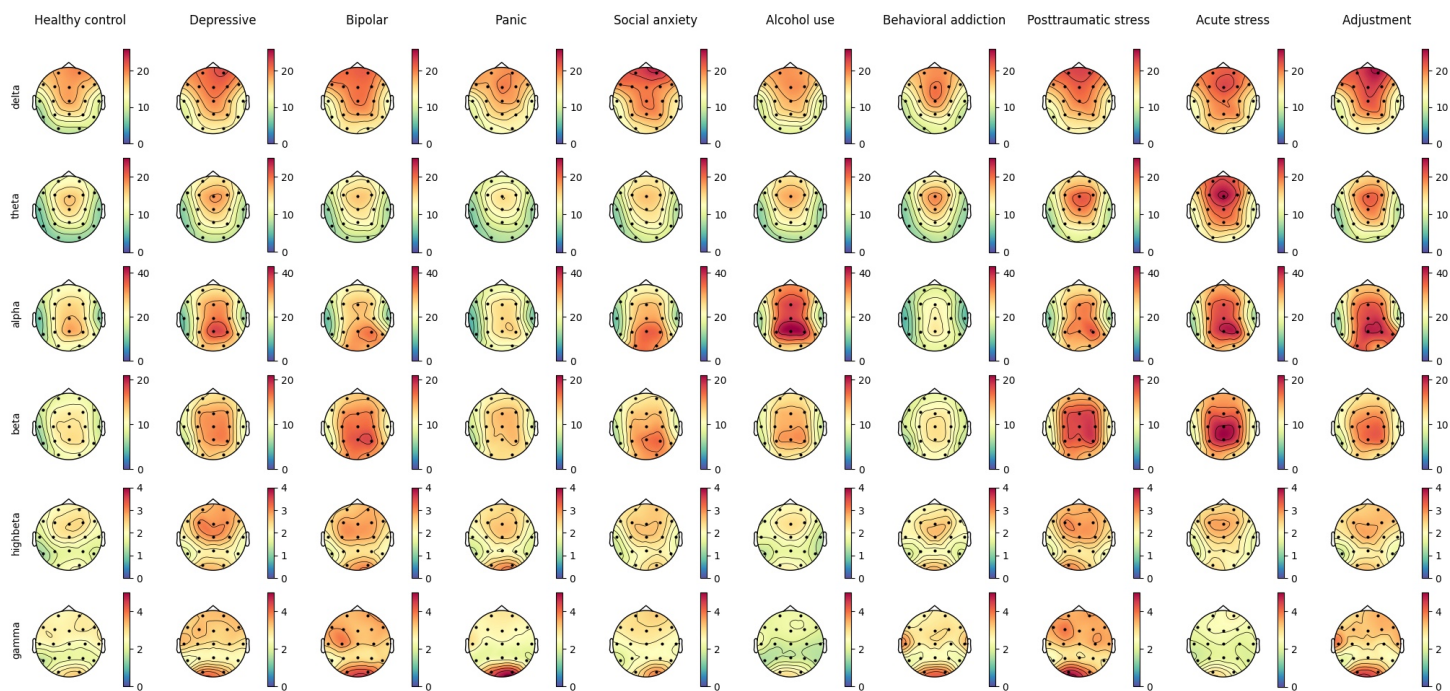
²⁰ $\mu V^2 / Hz$



شکل ۶.۳: تصویرسازی PSD برای اختلالات اصلی [۲۸]

همانطور که مشاهده می‌شود، تفاوت‌هایی در میانگین PSD مرتبط به QEEG بین افراد مبتلا به اختلال‌های مختلف وجود دارد. این نتایج نشان می‌دهند که ویژگی‌های فرکانسی مغز در افراد با اختلال‌های مختلف به طور متوسط متفاوت هستند. این تفاوت‌ها می‌توانند نشان‌دهنده تغییرات زیست‌ساختاری و عملکردی مغز در هر یک از گروه‌ها باشند.

تفاوت‌های مشاهده‌شده می‌توانند نشان‌دهنده اختلاف‌های محتمل در الگوهای فعالیت مغزی، تعادل بین فرکانس‌ها و نواحی مختلف مغزی و یا ارتباطات مغزی باشند که می‌تواند با تحلیل‌های تکمیلی بیشتر بررسی شود. این نتایج می‌توانند به درک بهتر از علت و مکانیسم‌های عملکردی اختلال‌های عصبی کمک کنند و مسیرهای درمانی جدید را ارائه کنند.



شکل ۷.۳: تصویرسازی PSD برای اختلالات جزئی [۲۸]

۲.۳ نتایج مدل‌ها

همانطور که پیش تر ذکر شد، به طور کلی عملکرد سه الگوریتم رگرسیون لجستیک و ماشین بردار پشتیبان و جنگل تصادفی بررسی شد. نتایج مدل‌ها به کمک معیارهای Mean Score و Std Score و همچنین دقت^{۲۱} سنجیده و مقایسه شد.

:Mean Score

- Mean Score نشان‌دهنده میانگین عملکرد مدل در دفعات مختلف آزمون است.
- هنگامی که الگوریتم با چند بار آزمایش اجرا می‌شود، نتایج آن هر دفعه با امتیازهای مختلف ثبت می‌شود. سپس میانگین این امتیازها به دست می‌آید.

:Std Score

- Std Score نشان‌دهنده پراکندگی نتایج مدل در آزمایش‌های مختلف است.
- این معیار نشان‌دهنده میزان تغییرات نتایج بین دفعات مختلف آزمون است.
- اگر Std Score بسیار کم باشد، نتایج مدل در آزمایش‌های مختلف به نسبت پایدار است.

دقت:

- معیار دقت نشان‌دهنده میزان صحت پیش‌بینی مدل بر روی داده‌های آزمون است.
- این معیار نسبت تعداد نمونه‌هایی که مدل به درستی پیش‌بینی کرده است به کل تعداد نمونه‌ها است.
- دقت بالا نشان‌دهنده صحت بالا در پیش‌بینی‌های مدل است. افزایش دقت، نشان می‌دهد که مدل عملکرد بهتری را دارد.
- در اینجا دقت، برابر با دقت آزمایشی است که بهترین نتیجه را داشت.

در ادامه به بررسی پارامترهای استفاده شده در هر الگوریتم می‌پردازیم. در رگرسیون لجستیک C قدرت کلی منظم‌سازی^{۲۲} را کنترل می‌کند و l1_ratio تعادل بین منظم‌سازی L1 و L2 را در الگوریتم ElasticNet کنترل می‌کند. C در ماشین بردار پشتیبان نیز قدرت منظم‌سازی را کنترل می‌کند.

²¹Accuracy

²²Regularization

در جنگل تصادفی، max_depth عمق هر یک از درختان تصمیم و n_estimators تعداد درختان تصمیم را مشخص می‌کنند.

جدول ۸.۳ نتایج طبقه‌بندی چندکلاسه با در نظر گرفتن تمام ویژگی‌ها بر روی اختلالات اصلی را نشان می‌دهد. مدل ماشین بردار پشتیبان دارای بالاترین mean score و دقت است که نشان می‌دهد به طور میانگین بهترین عملکرد را داشته. مدل رگرسیون لجستیک دارای دومین بهترین mean score و دقت است. مدل جنگل تصادفی کمترین mean score و دقت را دارد که نشان می‌دهد در بین سه مدل بدترین عملکرد را داشته است. مدل ماشین بردار پشتیبان دارای کمترین Std Score در بین سه مدل است، که نشان می‌دهد عملکرد آن در تاهای مختلف اعتبارسنجی متقابل نسبتاً سازگار است. مدل رگرسیون لجستیک Std Score کمی بالاتر نسبت به مدل ماشین بردار پشتیبان دارد. مدل جنگل تصادفی دارای بالاترین Std Score است که نشان دهنده تنوع بیشتر در عملکرد آن است. به‌طور کلی نتایج مدل ماشین پشتیبان از بقیه مدل‌ها بهتر بود که با در نظر گرفتن اینکه دیتاست ما دارای ۱۱۴۹ ستون و تنها ۹۴۵ سطر بود این نتیجه کاملاً منطقی می‌باشد زیرا این مدل برای داده‌هایی که تعداد کم با بعد بالا دارند به خوبی عمل می‌کند.

جدول ۸.۳: نتایج طبقه‌بندی بر روی اختلالات اصلی

Algorithm	Params	Mean Score	Std Score	Accuracy
EN	{'C': 0.5, 'l1_ratio': 1.0}	0.653078	0.035021	0.823065
SVM	{'C': 5}	0.612213	0.023951	0.988942
RF	{'max_depth': 1, 'n_estimators': 500}	0.637356	0.033529	0.278041

جدول ۹.۳ نیز نتایج طبقه‌بندی روی اختلالات اصلی می‌باشد اما ویژگی جنسیت از آن حذف شده. پیش‌تر گفته شده بود که ویژگی جنسیت بدلیل نا متوازن بودن داده‌ها بین دو جنس ممکن است باعث به وجود آمدن بایاس شود. در اینجا با حذف جنسیت از ویژگی‌ها، تغییر زیادی مشاهده نشد. دقت مدل ماشین پشتیبان ثابت ماند و دقت مدل رگرسیون لجستیک حدود ۲ درصد کمتر شد؛ در حالی که دقت روی جنگل تصادفی افزایش یافت. شایان ذکر هست که Std Score برای مدل‌های ماشین پشتیبان و جنگل تصادفی در جدول دوم کاهش یافت که نشان‌دهنده بهبود پایداری در عملکرد آنهاست.

جدول ۹.۳: نتایج طبقه‌بندی بر روی اختلالات اصلی با حذف ویژگی جنسیت

Algorithm	Params	Mean Score	Std Score	Accuracy
EN	{'C': 0.5, 'l1_ratio': 1.0}	0.632501	0.037757	0.808847
SVM	{'C': 5}	0.601100	0.023215	0.988942
RF	{'max_depth': 3, 'n_estimators': 500}	0.618134	0.023943	0.360190

جدول ۱۰.۳ نتایج طبقه‌بندی روی اختلالات جزئی با در نظر گرفتن تمام ویژگی‌ها را انجام

می‌دهد. به طور کلی مدل رگرسیون لجستیک بهترین عملکرد را داشته زیرا به طور کلی وقتی ورودی‌ها همبستگی بالایی دارند این مدل خوب عمل می‌کند. بدلیل اینکه در ElasticNet جریمه‌ی ^{۲۳} ridge و lasso را داریم، این مدل می‌تواند به طور مؤثر ویژگی‌های مربوطه را انتخاب کند و ویژگی‌های بسیار همبسته را به میانگین گیری تشویق کند.

جدول ۱۰.۳: نتایج طبقه‌بندی بر روی اختلالات جزئی

Algorithm	Params	Mean Score	Std Score	Accuracy
EN	{'C': 0.5, 'l1_ratio': 1.0}	0.625297	0.045593	0.810427
SVM	{'C': 1}	0.581727	0.040113	0.529226
RF	{'max_depth': 3, 'n_estimators': 100}	0.610953	0.028649	0.303318



جدول ۱۱.۳ نیز نتایج طبقه‌بندی روی اختلالات جزئی می‌باشد اما ویژگی جنسیت از آن حذف شده. پیش‌تر گفته شده بود که ویژگی جنسیت بدلیل نامتوازن بودن داده‌ها بین دو جنس ممکن است باعث به وجود آمدن بایاس شود. در اینجا با حذف جنسیت از ویژگی‌ها، دقت تمامی مدل‌ها کمی کاهش یافته است.

جدول ۱۱.۳: نتایج طبقه‌بندی بر روی اختلالات جزئی با حذف ویژگی جنسیت

Algorithm	Params	Mean Score	Std Score	Accuracy
EN	{'C': 0.5, 'l1_ratio': 1.0}	0.600574	0.045786	0.799368
SVM	{'C': 1}	0.578068	0.041259	0.527646
RF	{'max_depth': 3, 'n_estimators': 500}	0.581024	0.035336	0.300158

در این گزارش، تلاش‌هایی برای تحلیل داده‌های EEG با استفاده از شبکه‌های عصبی شده است. ابتدا از شبکه از قبل آماده EEGNet برای تحلیل داده‌ها استفاده شد. اما به دلیل پیچیدگی این شبکه، مشکل بیش‌برازش بر روی داده‌های آموزشی به وجود آمد. سپس از مدل‌های ساده‌تر شبکه عصبی پیچشی استفاده شد، اما باز هم با مشکل بیش‌برازش مواجه شد و عدم تعمیم‌پذیری مدل بر روی داده‌های تست با دقت پایینی مواجه شد. در این مورد، مشکل اصلی این است که مدل آموزش دیده بر روی داده‌های آموزشی قادر به تعمیم اطلاعات به داده‌های تست نیست. به عبارت دیگر، مدل قادر به تشخیص الگوها و ویژگی‌ها در داده‌های جدید نمی‌باشد و در نتیجه دقت پایینی بر روی داده‌های تست دارد. این مسئله می‌تواند به دلیل کمبود داده‌ها نسبت به پیچیدگی مدل و تعداد ویژگی‌ها رخ داده باشد.



²³Penalty



شکل ۹.۳: دقت در شبکه عصبی پیچشی

شکل ۸.۳: زیان در شبکه عصبی پیچشی

شکل ۱۰.۳



شکل ۱۲.۳: دقت در شبکه EEGNet

شکل ۱۱.۳: زیان در شبکه EEGNet

شکل ۱۳.۳

فصل ۴

جمع‌بندی

در این پروژه، هدف اصلی ما طبقه‌بندی اختلالات عصبی بر اساس داده‌های EEG بود. یکی از چالش‌های اساسی این پروژه، کمبود تعداد داده‌ها بود که باعث مشکلاتی در استفاده از مدل‌های شبکه عصبی گردید. همچنین، تعداد ویژگی‌ها در ستون‌ها به تعداد ۱۱۴۹ بود در حالی که تنها ۹۴۵ سطر داده داشتیم. اضافه کردن داده‌های بیشتر می‌تواند بهبود عملکرد کلی مدل‌های یادگیری ماشین را نیز به همراه داشته باشد. یک نکته‌ی مهم دیگر که در توضیحات داده مشخص شد، این است که اکثر داده‌ها مربوط به افراد کره‌ای هستند و فراوانی ملیتی در آن‌ها مشاهده نمی‌شود. این موضوع می‌تواند مشکلات مختلف هنگام تعمیم دادن نتایج به دیگر ملیت‌ها را در بر داشته باشد. در کل، با توجه به محدودیت‌های داده‌ای و کمبود تعداد داده‌ها، پیشنهاد می‌شود در آینده، تلاش بیشتری برای جمع‌آوری داده‌های بیشتر و متنوع انجام شود تا بتوانیم دقت و عملکرد مدل‌های طبقه‌بندی را بهبود دهیم. با این اصلاحات و بهبودها، امیدواریم که این پروژه نتایج بهتری را به ارمغان بیاورد و به تشخیص اختلالات عصبی با دقت بیشتری کمک کند.

واژه‌نامه فارسی به انگلیسی

Hyperplane	ابر صفحه
FC	اتصال‌ناپذیری کوهرانس
Mastoid Reference Electrode	الکتروود مرجع ماستوئید
Texture Synthesis Algorithms	الگوریتم‌های بافته‌سازی
Causality	انساب‌سنجی
Cross-validation	اعتبارسنجی متقابل
EEG	الکتروانسفالوگرام
Genetic Algorithm	الگوریتم ژنتیک
Fourier transform	تبدیل فوریه
FFT	تبدیل فوریه سریع
CCA	تحلیل کانونی
PET	تصویربرداری انباشت پوزیترون
fMRI	تصویربرداری مغناطیسی تابشی
Ensemble Learning	ترکیب مدل‌ها
Rorschach	تست رایینز
Medical Image Analysis	تحلیل تصویر پزشکی
Penalty	جریمه
Grid Search	جستجوی خطی
Random Forest	جنگل تصادفی
Bias	خطای ثابت
Output	خروجی
Nan Data	داده‌های ناقص
Accuracy	دقت
Decision tree	درخت تصمیم
Binary	دودویی
Biomedical Signal	سیگنال زیست پزشکی
Feedforward Networks	شبکه‌های پیشرو
Multi Layer perceptron	شبکه‌های عصبی چند لایه

Recurrent Neural Network.....	شبکه‌های عصبی بازگشتی
Convolutional Neural Networks.....	شبکه‌های عصبی پیچشی
Artificial Neural Networks	شبکه‌های عصبی مصنوعی
ElasticNet	شبکه الاستیک
Precision.....	صحت
Retrospective Study Design	طراحی بازبینی
Performance	عملکرد
Fuzzification	فازی‌سازی
PCA.....	کمانش مؤلفه‌ها
FFT Cross-spectral Matrix.....	ماتریس تبدیل فوریه سریع
Support Vector Machine.....	ماشین بردار پشتیبان
Special Value.....	مقدار ویژه
Beck Depression Inventory	مقیاس افسردگی بک
Median	مد
Mean	میانگین
MSE.....	میانگین مربعات خطا
MEG	مگنتوانسفالوگرام
Regularization	منظم‌سازی
leakage.....	نشتی‌اژ
Windowing.....	نوابک‌زدایی
Neuroscience	نوروساینس
Correlated.....	همبسته
Inputs	ورودی
Weights	وزن‌ها
Supervised Machine Learning.....	یادگیری با نظارت
Unsupervised Machine Learning	یادگیری بدون نظارت
Semi-supervised Machine Learning.....	یادگیری نیمه‌نظارتی

واژه‌نامه انگلیسی به فارسی

Artificial Neural Networks	شبکه‌های عصبی مصنوعی
Backpropagation	پس‌انتشار
Beck Depression Inventory	مقیاس افسردگی بک
Bias	خطای ثابت
Biomedical Signal	سیگنال زیست پزشکی
Binary	دودویی
CCA (Canonical Correlation Analysis)	تحلیل کانونی
Convolutional Neural Networks (CNN)	شبکه‌های عصبی پیچشی
Cost Function	تابع هزینه
Cross-validation	اعتبارسنجی متقابل
Decision tree	درخت تصمیم
EEG (Electroencephalogram)	الکتروانسفالوگرام
ElasticNet	شبکه الاستیک
Ensemble Learning	ترکیب مدل‌ها
fMRI	تصویربرداری مغناطیسی تابشی
FC (Functional Connectivity)	اتصال‌ناپذیری کوهرانس
Feedforward Networks	شبکه‌های پیشرو
FFT (Fast Fourier Transform)	تبدیل فوریه سریع
FFT Cross-spectral Matrix	ماتریس تبدیل فوریه سریع
Fourier transform	تبدیل فوریه
Fuzzification	فازی‌سازی
Genetic Algorithm	الگوریتم ژنتیک
Gradient Descent	گرادیان کاهشی
Ground Channel	کانال زمین
Grid Search	جستجوی خطی
Hyperplane	ابر صفحه
Imputation	روش پیش‌بینی

Inputs	ورودی
Leakage	نشتیاز
Logistic Regression	رگرسیون لجستیک
Mastoid Reference Electrode.....	الکتروود مرجع ماستوئید
Mean	میانگین
MEG (Magnetoencephalogram)	مگنتوانسفالوگرام
Median	مد
Medical Image Analysis.....	تحلیل تصویر پزشکی
MSE (Mean Squared Error).....	میانگین مربعات خطا
Multi Layer perceptron.....	شبکه‌های عصبی چند لایه
Nan Data.....	داده‌های ناقص
Neuroscience	نوروساینس
NIRS (Near-Infrared Spectroscopy)	اسپکتروسکوپی اشعه نزدیک نوری
Overfitting.....	برازش بیش از حد
Output.....	خروجی
PCA (Principal Component Analysis)	کمانش مؤلفه‌ها
Penalty	جریمه
PET (Positron Emission Tomography)	تصویربرداری انباشت پوزیترون
Precision.....	صحت
PSD (Power Spectral Density).....	چگالی طیفی توان
Random Forest	جنگل تصادفی
Recall.....	بازخوانی
Regularization	منظم‌سازی
Retrospective Study Design	طراحی بازبینی
Rorschach Test	تست رایبنز
Supervised Machine Learning.....	یادگیری با نظارت
Support Vector Machine (SVM).....	ماشین بردار پشتیبان
Texture Synthesis Algorithms	الگوریتم‌های بافته‌سازی
Unsupervised Machine Learning	یادگیری بدون نظارت
Weights	وزن‌ها
Windowing.....	نوابک‌زدایی

Bibliography

- [1] Park, S. M., & Jung, H. Y. (2020). Respiratory sinus arrhythmia biofeedback alters heart rate variability and default mode network connectivity in major depressive disorder: a preliminary study. *International Journal of Psychophysiology*, 158, 225-237. doi:10.1016/j.ijpsycho.2020.10.008
- [2] Guevara, M. A., & Corsi-Cabrera, M. (1996). EEG coherence or EEG correlation? *International Journal of Psychophysiology*, 23, 145-153. doi:10.1016/S0167-8760(96)00038-4
- [3] Nunez, P. L., Silberstein, R. B., Shi, Z., Carpenter, M. R., Srinivasan, R., Tucker, D. M., et al. (1999). EEG coherency II: experimental comparisons of multiple measures. *Clinical Neurophysiology*, 110, 469-486. doi:10.1016/S1388-2457(98)00043-1
- [4] Kaiser, J., & Gruzelier, J. H. (1996). Timing of puberty and EEG coherence during photic stimulation. *International Journal of Psychophysiology*, 21, 135-149. doi:10.1016/0167-8760(95)00048-8
- [5] Thatcher, R. W., North, D. M., & Biver, C. J. (2008). Development of cortical connections as measured by EEG coherence and phase delays. *Human Brain Mapping*, 29, 1400-1415. doi:10.1002/hbm.20474
- [6] Thatcher, R. W., North, D. M., & Biver, C. J. (2005). EEG and intelligence: relations between EEG coherence, EEG phase delay, and power. *Clinical Neurophysiology*, 116, 2129-2141. doi:10.1016/j.clinph.2005.04.026
- [7] Dwyer, D. B., Falkai, P., & Koutsouleris, N. (2018). Machine learning approaches for clinical psychology and psychiatry. *Annual Review of*

Clinical Psychology, 14, 91-118. doi:10.1146/annurev-clinpsy-032816-045037

- [8] Steardo, L., Jr., Carbone, E. A., de Filippis, R., Pisanu, C., Segura-Garcia, C., Squassina, A., et al. (2020). Application of support vector machine on fMRI data as biomarkers in schizophrenia diagnosis: a systematic review. *Frontiers in Psychiatry*, 11, 588. doi:10.3389/fpsy.2020.00588
- [9] Shim, M., Hwang, H. J., Kim, D. W., Lee, S. H., & Im, C. H. (2016). Machine-learning-based diagnosis of schizophrenia using combined sensor-level and source-level EEG features. *Schizophrenia Research*, 176, 314-319. doi:10.1016/j.schres.2016.05.007
- [10] Ieracitano, C., Mammone, N., Hussain, A., & Morabito, F. C. (2020). A novel multi-modal machine learning based approach for automatic classification of EEG recordings in dementia. *Neural Networks*, 123, 176-190. doi:10.1016/j.neunet.2019.12.006
- [11] Mumtaz, W., Ali, S. S. A., Yasin, M. A. M., & Malik, A. S. (2008). A machine learning framework involving EEG-based functional connectivity to diagnose major depressive disorder (MDD). *Medical & Biological Engineering & Computing*, 56, 233-246. doi:10.1007/s11517-017-1685-z
- [12] Kim, Y. W., Kim, S., Shim, M., Jin, M. J., Jeon, H., Lee, S. H., et al. (2020). Riemannian classifier enhances the accuracy of machine-learning-based diagnosis of PTSD using resting EEG. *Progress in Neuro-Psychopharmacology and Biological Psychiatry*, 102, 109960. doi:10.1016/j.pnpbp.2020.109960
- [13] American Psychiatric Association. (2013). Diagnostic and statistical manual of mental disorders (5th ed.). Arlington, VA: American Psychiatric Publishing.
- [14] National Institute of Mental Health (NIMH). (n.d.). Mental Disorders.
- [15] American Psychiatric Association. (2013). Diagnostic and Statistical Manual of Mental Disorders (DSM-5). Arlington, VA: American Psychiatric Publishing.

- [16] Achenbach, T. M., & Rescorla, L. A. (2001). Manual for the ASEBA School-Age Forms & Profiles: An Integrated System of Multi-Informant Assessment. Burlington, VT: University of Vermont, Research Center for Children, Youth, & Families.
- [17] Beck, A. T., Steer, R. A., & Brown, G. K. (1996). Beck Depression Inventory-II. San Antonio, TX: Psychological Corporation.
- [18] Meyer, G. J., Viglione, D. J., Mihura, J. L., Erard, R. E., & Erdberg, P. (2011). Rorschach Performance Assessment System: Administration, Coding, Interpretation, and Technical Manual (2nd ed.). Toledo, OH: Rorschach Performance Assessment System.
- [19] Hersen, M., & Gross, A. M. (Eds.). (2008). Handbook of Clinical Psychology (4th ed.). Hoboken, NJ: John Wiley & Sons.
- [20] McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4), 115–133. doi:10.1007/BF02478259
- [21] IBM. (n.d.). *IBM - Neural Networks*. Retrieved from <https://www.ibm.com/topics/neural-networks>
- [22] Wikipedia. (n.d.). *Sigmoid function*. Retrieved from https://en.wikipedia.org/wiki/Sigmoid_function
- [23] Wikipedia. (n.d.). *Support vector machine*. Retrieved from https://en.wikipedia.org/wiki/Support_vector_machine
- [24] IBM. (n.d.). *Random Forest*. Retrieved from <https://www.ibm.com/topics/random-forest>
- [25] Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. *Psychological Review*, 65(6), 386–408. doi:10.1037/h0042519
- [26] Werbos, P. (1974). Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences. Unpublished Doctoral Dissertation, Harvard University.

- [27] LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., & Jackel, L. D. (1989). Backpropagation Applied to Handwritten Zip Code Recognition. *Neural Computation*, 1(4), 541-551. doi:10.1162/neco.1989.1.4.541
- [28] Park, S. M., Jeong, B., Oh, D. Y., Choi, C. H., Jung, H. Y., Lee, J. Y., Lee, D., & Choi, J. S. (2021). Identification of Major Psychiatric Disorders From Resting-State Electroencephalography Using a Machine Learning Approach. *Frontiers in Psychiatry*, 12, 707581. doi:10.3389/fpsyt.2021.707581
- [29] World Health Organization. (1992). *The ICD-10 Classification of Mental and Behavioural Disorders: Clinical Descriptions and Diagnostic Guidelines*. World Health Organization.
- [30] American Psychiatric Association. (2013). *Diagnostic and Statistical Manual of Mental Disorders*. 5th ed. Arlington, VA: American Psychiatric Association.
- [31] Insel TR. (2014). The NIMH research domain criteria (RDoC) project: precision medicine for psychiatry. *Am J Psychiatry*, 171, 395-397. doi:10.1176/appi.ajp.2014.14020138
- [32] Zhang X, Braun U, Tost H, Bassett DS. (2020). Data-driven approaches to neuroimaging analysis to enhance psychiatric diagnosis and therapy. *Biol Psychiatry Cogn Neurosci Neuroimaging*, 5, 780-790. doi:10.1016/j.bpsc.2019.12.015
- [33] Huys QJM, Maia TV, Frank MJ. (2016). Computational psychiatry as a bridge from neuroscience to clinical applications. *Nat Neurosci*, 19, 404-413. doi:10.1038/nn.4238
- [34] Bzdok D, Yeo BTT. (2017). Inference in the age of big data: future perspectives on neuroscience. *Neuroimage*, 155, 549-564. doi:10.1016/j.neuroimage.2017.04.061
- [35] Simon GE. (2019). Big data from health records in mental health care: hardly clairvoyant but already useful. *JAMA Psychiatry*, 76, 349-350. doi:10.1001/jamapsychiatry.2018.4510

- [36] Klöppel S, Stonnington CM, Chu C, Draganski B, Scahill RI, Rohrer JD, et al. (2008). Automatic classification of MR scans in Alzheimer's disease. *Brain*, 131, 681-689. doi:10.1093/brain/awm319

Abstract

In this report, we focus on the classification of mental disorders based on EEG data and investigate the performance of various models, including logistic regression, support vector machine, and random forest. The experimental results demonstrate that the support vector machine model has shown better performance in classifying major disorders, while the logistic regression model has provided better results for classifying specific disorders. The utilized data includes IQ, age, gender, medical diagnoses, EEG wave power spectral density (PSD) features, and functional connectivity (FC) features. Overall, we had 945 data samples, with 850 samples belonging to patients with mental disorders and 95 samples representing healthy individuals. The outcomes of this project indicate that the use of EEG features can be effective in diagnosing and classifying mental disorders, and employing different machine learning models based on the type of disorder can lead to improved accuracy and performance in this domain.



College of Science
School of Mathematics, Statistics, and Computer Science

Classification of Mental Disorders Using EEG Data

Niloufar Baba Ahmadi

Supervisor: Bagher Babaali

A thesis submitted in partial fulfillment of the requirements for
the degree of B.Sc. Computer Science

2023